

## 第 6 章 大样本 OLS

### 6.1 为何需要大样本理论

大样本理论(large sample theory)，也称渐近理论(asymptotic theory)，研究当样本容量 $n$ 趋向无穷大时统计量的性质。

大样本理论已成为当代计量经济学的主流方法，原因如下。

(1) 小样本理论的假设过强。首先，小样本理论的严格外生性假设要求解释变量与所有的扰动项均正交(不相关)。在时间序列模型中，这意味着解释变量与扰动项的过去、现在与未来值全部正交！

例 一阶自回归模型(first order autoregression, 简记 AR(1)):

$$y_t = \rho y_{t-1} + \varepsilon_t \quad (t = 2, \dots, T) \quad (6.1)$$

解释变量  $y_{t-1}$  为被解释变量  $y_t$  的一阶滞后; 且  $\text{Cov}(y_{t-1}, \varepsilon_t) = 0$ 。

严格外生性要求, 解释变量  $y_{t-1}$  与所有  $\{\varepsilon_2, \dots, \varepsilon_T\}$  均不相关。

这意味着,  $y_t$  也不与  $\varepsilon_t$  相关。

根据自回归方程(6.1),  $\varepsilon_t$  是  $y_t$  的一部分, 故二者一定相关, 因为

$$\text{Cov}(y_t, \varepsilon_t) = \text{Cov}[(\rho y_{t-1} + \varepsilon_t), \varepsilon_t] = \rho \underbrace{\text{Cov}(y_{t-1}, \varepsilon_t)}_{=0} + \text{Var}(\varepsilon_t) = \text{Var}(\varepsilon_t) : \quad (6.2)$$

因此，以被解释变量滞后值为解释变量的自回归模型，必然违背严格外生性的假定。

大样本理论只要求解释变量与同期(同方程)的扰动项不相关。

其次，小样本理论假定扰动项为正态分布，而大样本理论无此限制。

在很多情况下，我们并无把握经济变量是否服从正态分布。比如，正态分布为对称分布，但许多经济变量的分布并不对称，例如工资收入。

即使考虑比较对称的工资对数，由于正态变量的取值范围为 $(-\infty, +\infty)$ ，而工资对数一般为正数(假设工资大于1)，故也不相符。

作为示例，下面将数据集 `grilic.dta` 的工资与工资对数的核密度图画在一起，结果参见图 6.1。

```
. use grilic.dta,clear
. gen wage=exp(lnw)
. twoway kdensity wage,xaxis(1) yaxis(1)
xvarlab(wage) || kdensity lnw,xaxis(2) yaxis(2)
xvarlab(ln(wage)) lp(dash)
```

选择项 “`xaxis(1) yaxis(1)`” 与 “`xaxis(2) yaxis(2)`” 指定对于变量 *wage* 与 *lnw* 分别使用不同的 *x* 轴与 *y* 轴，因为这两个变量的取值范围与概率密度均很不相同；

选择项 “`xvarlab(wage)`” 与 “`xvarlab(ln(wage))`” 将变量 *wage* 与 *lnw* 核密度图的横轴标签分别指定为 “*wage*” 与 “*ln(wage)*”。

从图 6.1 可知,工资的分布与正态分布相去甚远;即使工资对数,在取值范围为 $(-\infty, +\infty)$ 这一点上,也与正态分布不符。




图 6.1 工资与工资对数的分布

被解释变量的分布可能为各种形状；有时即使取对数也不能使其接近正态分布。

继续以数据集 `grilic.dta` 为例，将教育年限( $s$ )与其对数( $\ln s$ )的核密度图画在一起，结果参见图 6.2。

```
. gen lns=log(s)

. twoway kdensity s,xaxis(1) yaxis(1) xvarlab(s)
|| kdensity lns,xaxis(2) yaxis(2) xvarlab(lns)
lp(dash)
```

教育年限的分布呈现“双峰”形状，多数人为中学或大学毕业。

这种双峰形状，即使取对数后，也难以改变。




图 6.2 教育年限  $s$  与其对数  $lns$  的分布

无论教育年限还是其对数的分布，都与“单峰”的正态分布相去甚远。

这也说明，通过取对数使得变量的分布接近于正态并非万能。

对于小样本理论来说，为了进行统计推断(比如，推导 $t$ 统计量与 $F$ 统计量的有限样本分布)，必须假设扰动项服从正态分布(故被解释变量也服从正态分布)。

由于现实中的被解释变量可能服从各种分布(比如，变量婚否  $mrt$  为离散的两点分布)，故基于正态假设的小样本理论的适用范围受到很大限制。



(2) 在小样本理论的框架下，必须研究统计量的精确分布(exact distribution)，但常难以推导(即使在正态分布的假设之下)。

根据大样本理论，只要研究统计量的大样本分布，即当 $n \rightarrow \infty$ 时的渐近分布，相对比较容易推导(可使用大数定律与中心极限定理)。

(3) 使用大样本理论的代价是要求样本容量较大，以便大数定律与中心极限定理可以起作用。

大样本理论对于样本容量的要求，一般认为至少 $n \geq 30$ ，最好在100 以上。

现代的数据集越来越大，经常成百上千(对于大数据，样本容量可能过亿)，使得渐近理论成为对统计量真实分布的很好近似。

## 6.2 随机收敛

### 1. 确定性序列的收敛

**定义** 确定性序列  $\{a_n\}_{n=1}^{\infty} = \{a_1, a_2, a_3, \dots\}$  收敛(converge)于常数  $a$ , 记为  $\lim_{n \rightarrow \infty} a_n = a$  或  $a_n \rightarrow a$ , 如果对于任意小的正数  $\varepsilon > 0$ , 都存在  $N > 0$ , 只要  $n > N$ , 就有  $|a_n - a| < \varepsilon$ , 即在  $a_N$  以后的序列  $\{a_{N+1}, a_{N+2}, \dots\}$  均落入区间  $(a - \varepsilon, a + \varepsilon)$  内, 参见图 6.3。

此定义意味着, 无论区间  $(a - \varepsilon, a + \varepsilon)$  多么小, 如果去看序列  $\{a_n\}_{n=1}^{\infty}$  “足够后面” (比如  $n > N$ ) 的项, 则就会都落入此区间内。




图 6.3 确定性序列的收敛

例 假设  $a_n = 5 + \frac{1}{n}$ , 则  $\lim_{n \rightarrow \infty} a_n = \lim_{n \rightarrow \infty} (5 + \frac{1}{n}) = 5 + \lim_{n \rightarrow \infty} \frac{1}{n} = 5 + 0 = 5$ 。

## 2. 随机序列的收敛

考虑随机序列  $\{x_n\}_{n=1}^{\infty} = \{x_1, x_2, x_3, \dots\}$ , 即由随机变量构成的序列, 其中每个元素  $x_n$  都是随机变量, 而下标  $n$  通常表示样本容量。

定义 随机序列 $\{x_n\}_{n=1}^{\infty}$ 依概率收敛(converge in probability)于常数  $a$ , 记为 $\text{plim}_{n \rightarrow \infty} x_n = a$ , 或 $x_n \xrightarrow{p} a$ , 如果对于任意 $\varepsilon > 0$ , 当 $n \rightarrow \infty$ 时, 都有 $\lim_{n \rightarrow \infty} P(|x_n - a| > \varepsilon) = 0$ 。




图 6.4 随机序列的收敛

这意味着，任意给定很小的正数  $\varepsilon > 0$ ，当  $n$  越来越大时，随机变量  $x_n$  落在区间  $(a - \varepsilon, a + \varepsilon)$  之外的概率收敛于 0，参见图 6.4。

当  $n$  变大时， $x_n$  远离常数  $a$  的可能性越来越小，变得几乎不可能。

虽然  $x_n$  为随机变量，各种取值都有可能，但当  $n \rightarrow \infty$  时， $x_n$  的取值可能性越来越集中于  $a$  附近。

由于已将随机事件  $(|x_n - a| > \varepsilon)$  取概率，故  $P(|x_n - a| > \varepsilon)$  其实是确定性序列。

$\lim_{n \rightarrow \infty} P(|x_n - a| > \varepsilon)$  只是普通的微积分极限。

例 假设  $x_n$  服从如下两点分布：

$$x_n = \begin{cases} 0 & \text{取值概率 } 1-1/n \\ n & \text{取值概率 } 1/n \end{cases} \quad (6.3)$$

随着  $n \rightarrow \infty$ ， $x_n$  的分布越来越集中于 0，而取值为  $n$  的可能性越来越小(尽管  $n$  离 0 越来越远)。

故根据定义， $\text{plim}_{n \rightarrow \infty} x_n = 0$ 。

利用随机变量依概率收敛于常数的概念，可定义随机变量之间的随机收敛，只要随机变量之差别依概率收敛于 0。

定义 随机序列  $\{x_n\}_{n=1}^{\infty}$  依概率收敛于随机变量  $x$ ，记为  $x_n \xrightarrow{p} x$ ，如果随机序列  $\{x_n - x\}_{n=1}^{\infty}$  依概率收敛于 0。

概率收敛( $\text{plim}$ )的运算规则类似于微积分中极限( $\lim$ )的运算。

比如，假设  $g(\cdot)$  为连续函数，则

$$\text{plim}_{n \rightarrow \infty} g(x_n) = g\left(\text{plim}_{n \rightarrow \infty} x_n\right) \quad (6.4)$$

此结论称为连续映射定理(Continuous Mapping Theorem)。

概率极限  $\text{plim}_{n \rightarrow \infty}$  与连续函数  $g(\cdot)$  可交换运算次序。

无论先用函数  $g(\cdot)$  去作用  $x_n$ ，再取概率极限；还是先对  $x_n$  取概率极限，再用函数  $g(\cdot)$  去作用，二者的效果是一样的。

当  $x_n$  的分布越来越集中于  $x^* \equiv \text{plim}_{n \rightarrow \infty} x_n$  附近时， $g(x_n)$  的分布自然也就越来越集中于  $g(x^*)$  附近。

但期望算子  $E(\cdot)$  无此性质。

一般来说， $E(x^2) \neq [E(x)]^2$ 。

这正是大样本理论的方便之处。



例 如果  $\text{plim}_{n \rightarrow \infty} s^2 = \sigma^2$  (样本方差依概率收敛于总体方差), 则样本标准差  $s$  也依概率收敛于总体标准差  $\sigma$ , 因为

$$\text{plim}_{n \rightarrow \infty} s = \text{plim}_{n \rightarrow \infty} \sqrt{s^2} = \sqrt{\text{plim}_{n \rightarrow \infty} s^2} = \sqrt{\sigma^2} = \sigma \quad (6.5)$$

其中, “开根号” ( $\sqrt{\quad}$ ) 是连续函数, 故可与求概率极限的运算交换次序。

对于随机向量序列(即序列中每个元素都是随机向量), 也可类似地定义依概率收敛, 只要定义其每个分量都依概率收敛即可。

比如, 随机向量序列  $\{\mathbf{x}_n\}_{n=1}^{\infty} = \{\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3 \cdots\}$  依概率收敛于随机向量  $\mathbf{x}$ , 意味着  $\mathbf{x}_n$  的每个分量都依概率收敛至  $\boldsymbol{\beta}$  的相应分量, 记为  $\text{plim}_{n \rightarrow \infty} \mathbf{x}_n = \mathbf{x}$ 。

### 3. 依均方收敛

**定义** 如果随机序列  $\{x_n\}_{n=1}^{\infty}$  的期望收敛于  $a$ , 即  $\lim_{n \rightarrow \infty} E(x_n) = a$ ; 而方差收敛于 0, 即  $\lim_{n \rightarrow \infty} \text{Var}(x_n) = 0$ , 则称  $\{x_n\}_{n=1}^{\infty}$  依均方收敛 (converge in mean square) 于常数  $a$ , 记为  $x_n \xrightarrow{ms} a$ 。

通过切比雪夫不等式, 可以证明(参见附录), 依均方收敛意味着依概率收敛。

当  $x_n$  的均值越来越趋于  $a$ ，而方差越来越小并趋于 0 时，就有  $\text{plim}_{n \rightarrow \infty} x_n = a$ ，即在极限处  $x_n$  退化为常数  $a$ 。

证明均方收敛通常比证明概率收敛更容易，故可通过证明前者来证明后者，这也是依均方收敛概念的主要用途之一。

反之，依概率收敛并不意味着均方收敛。

例 回到  $\{x_n\}$  服从两点分布的例子，即  $x_n$  取值为 0 的概率为  $1-1/n$ ，而取值为  $n$  的概率为  $1/n$ 。虽然  $x_n$  依概率收敛到 0，但  $x_n$  并不依均方收敛到 0，因为此序列的期望恒等于 1：

$$\lim_{n \rightarrow \infty} E(x_n) = \lim_{n \rightarrow \infty} \left[ 0 \cdot \left( 1 - \frac{1}{n} \right) + n \cdot \frac{1}{n} \right] = 1 \neq 0 \quad (6.6)$$

随着  $n \rightarrow \infty$ , 随机序列  $x_n$  取值大于 0 的概率越来越小(为  $1/n$ ), 但一旦取值为正数, 则很大(等于  $n$ ), 故此序列的期望始终为 1。

此序列的方差发散, 即  $\lim_{n \rightarrow \infty} \text{Var}(x_n) = \infty$  (参见习题)。

#### 4. 依分布收敛

**定义** 记随机序列  $\{x_n\}_{n=1}^{\infty}$  与随机变量  $x$  的累积分布函数分别为  $F_n(x)$  与  $F(x)$ 。如果对于任意给定  $x$ , 都有  $\lim_{n \rightarrow \infty} F_n(x) = F(x)$ , 则称随机序列  $\{x_n\}_{n=1}^{\infty}$  **依分布收敛**(converge in distribution)于随机变量  $x$ , 记为  $x_n \xrightarrow{d} x$ , 并称  $x$  的分布为  $x_n$  的**渐近分布**(asymptotic distribution)或**极限分布**(limiting distribution)。

这意味着，当 $n \rightarrow \infty$ 时， $x_n$ 的分布函数(概率密度函数)越来越像 $x$ 的分布函数(概率密度函数)。

与依概率收敛或依均方收敛不同，依分布收敛并非随机变量序列本身的收敛，而本质上是(分布)函数序列(sequence of functions)的收敛，已无不确定性。

例 当 $t$ 分布的自由度越来越大时， $t$ 分布依分布收敛于标准正态分布；即当 $k \rightarrow \infty$ 时， $t(k) \xrightarrow{d} N(0,1)$ 。

为了显示依分布收敛的过程，在 Stata 中画  $N(0, 1)$ ， $t(1)$ 与  $t(5)$  的累积分布函数，结果参见图 6.5。

```
. twoway function N=normal(x) ,range(-5 5) ||  
function t1=t(1,x),range(-5 5) lp(dash) ||  
function t5=t(5,x),range(-5 5) lp(shortdash)  
yttitle("累积分布函数")
```

其中，选择项 “lp(shortdash) ” 表示以短横来画线。




图 6.5 依分布收敛(累积分布函数)

通过概率密度函数，考察 $t$ 分布依分布收敛于标准正态的过程，结果参见图 6.6。

```
. twoway function N=normalden(x) ,range(-5 5) ||  
function t1=tden(1,x),range(-5 5) lp(dash) ||  
function t5=tden(5,x),range(-5 5) lp(shortdash)  
yttitle("概率密度")
```






图 6.6 依分布收敛(概率密度函数)

在计量经济学中，许多统计量的大样本分布均为正态分布，故引入如下概念。

**定义** 如果  $x_n \xrightarrow{d} x$ ，且  $x$  服从正态分布，则称  $x_n$  为渐近正态 (asymptotically normal)，即当  $n \rightarrow \infty$  时， $x_n$  的分布越来越像正态分布。

依分布收敛的运算也很方便。

比如，假设  $x_n \xrightarrow{d} x$ ，而  $g(\cdot)$  为连续函数，则  $g(x_n)$  的渐近分布就是  $g(x)$ ，即  $g(x_n) \xrightarrow{d} g(x)$ 。

当  $x_n$  的分布越来越像  $x$  的分布时， $g(x_n)$  的分布自然也越来越像  $g(x)$  的分布。

此结论也称为连续映射定理(Continuous Mapping Theorem)。

连续映射定理既适用于依概率收敛，也适用于依分布收敛。

例 假设  $x_n \xrightarrow{d} z$ ，其中  $z \sim N(0, 1)$ ，则  $x_n^2 \xrightarrow{d} z^2$ ，其中  $z^2 \sim \chi^2(1)$ ，即  $x_n^2 \xrightarrow{d} \chi^2(1)$ ，因为平方是连续函数。这意味着，渐近标准正态的平方服从渐近  $\chi^2(1)$  的分布。

“依概率收敛”比“依分布收敛”更强，前者是后者的充分条件；但反之，则不然。

首先，如果  $x_n \xrightarrow{p} x$ ，则意味着  $(x_n - x) \xrightarrow{p} 0$ ，即在极限处  $x_n$  与  $x$  的具体取值并无区别，故二者的概率分布也必然相同，所以  $x_n \xrightarrow{d} x$ 。

其次, 如果  $x_n \xrightarrow{d} x$ , 这只说明在极限处  $x_n$  与  $x$  的分布函数相同, 但  $x_n$  与  $x$  的实际取值仍可以很不相同(比如,  $x_n$  与  $x$  相互独立)。

依分布收敛只是分布函数的收敛(随机变量之间可以毫无关系), 而依概率收敛才是随机变量本身的收敛。

**例** 假设  $x$  与  $y$  都为标准正态, 且相互独立。考虑随机序列  $\{x_n = x + (1/n)\}_{n=1}^{\infty}$ 。

由于  $1/n \rightarrow 0$ , 故  $x_n$  的渐近分布为标准正态, 因此  $x_n \xrightarrow{d} y$  ( $y$  也是标准正态)。

但  $x_n$  却与  $y$  相互独立,  $x_n$  的具体取值也与  $y$  毫无关系, 故  $x_n$  并不依概率收敛于  $y$ 。

随机收敛的三个概念之间的强弱关系为：

依均方收敛  $\Rightarrow$  依概率收敛  $\Rightarrow$  依分布收敛

反之，此箭头的相反方向则不成立。

## 6.3 大数定律与中心极限定理

### 1. 大数定律(Law of Large Numbers)

假定  $\{x_n\}_{n=1}^{\infty}$  为独立同分布的随机序列，且  $E(x_1) = \mu$ ，

$\text{Var}(x_1) = \sigma^2$  存在，则样本均值  $\bar{x}_n \equiv \frac{1}{n} \sum_{i=1}^n x_i \xrightarrow{p} \mu$ 。

证明：首先， $E(\bar{x}_n) = \frac{1}{n} \sum_{i=1}^n E(x_i) = \frac{1}{n} \cdot n\mu = \mu$ ，故样本均值 $\bar{x}_n$ 的期望仍为 $\mu$ 。

其次， $\text{Var}(\bar{x}_n) = \text{Var}\left(\frac{x_1 + \cdots + x_n}{n}\right) = \frac{1}{n^2}(n\sigma^2) = \frac{\sigma^2}{n} \rightarrow 0$ ，样本均值 $\bar{x}_n$ 的方差收敛到 0。

因此， $\bar{x}_n$  依均方收敛于 $\mu$ 。

由于“依均方收敛”是“依概率收敛”的充分条件，故 $\bar{x}_n \xrightarrow{p} \mu$ 。

当样本容量 $n$ 很大时，样本均值趋于总体均值，故名“大数定律”。

## 2. 中心极限定理(Central Limit Theorem)

根据大数定律, 当 $n \rightarrow \infty$ 时, 样本均值 $\bar{x}_n$ 依概率收敛到总体均值 $\mu$ 。

在一般情况下,  $\bar{x}_n$ 的具体分布则很难推导。

中心极限定理告诉我们, 无论原序列 $\{x_n\}_{n=1}^{\infty}$ 服从什么分布, 当 $n \rightarrow \infty$ 时, 样本均值 $\bar{x}_n$ 的渐近分布都为正态分布。

只要样本容量 $n$ 足够大, 则 $\bar{x}_n$ 的真实分布将很接近于正态分布。

故可用正态分布来很好地近似 $\bar{x}_n$ 的真实分布(此真实分布通常无法求解), 并以此渐近分布作为统计推断的基础。

中心极限定理 假定  $\{x_n\}_{n=1}^{\infty}$  为独立同分布的随机序列，且  $E(x_1) = \mu$ ， $\text{Var}(x_1) = \sigma^2$  存在，则

$$\frac{\bar{x}_n - \mu}{\sqrt{\sigma^2/n}} \xrightarrow{d} N(0, 1) \quad (6.7)$$

标准化之后的样本均值(即减去期望，除以标准差)的渐近分布为标准正态。

直观上，可视为  $\bar{x}_n \xrightarrow{d} N(\mu, \sigma^2/n)$ ；但不严格，因为  $\bar{x}_n$  的方差  $\sigma^2/n \rightarrow 0$ 。



根据连续映射定理, 将表达式(6.7)两边同乘 $\sigma$ , 并将分母的 $\sqrt{1/n}$ 放到分子上, 可得中心极限定理的等价表达式:

$$\sqrt{n}(\bar{x}_n - \mu) \xrightarrow{d} N(0, \sigma^2) \quad (6.8)$$

显然,  $\sqrt{n} \rightarrow \infty$ ; 而根据大数定律,  $(\bar{x}_n - \mu) \xrightarrow{p} 0$ , 故上式用 $\sqrt{n} \cdot (\bar{x}_n - \mu)$ (即“ $\infty \cdot 0$ ”型)得到非退化的渐近正态分布。

表达式(6.8)的好处是, 容易推广到多维的情形。

**多维的中心极限定理:** 假定 $\{\mathbf{x}_n\}_{n=1}^{\infty}$ 为独立同分布的随机向量序列, 且 $E(\mathbf{x}_1) = \boldsymbol{\mu}$ ,  $\text{Var}(\mathbf{x}_1) = \boldsymbol{\Sigma}$ 存在, 则 $\sqrt{n}(\bar{\mathbf{x}}_n - \boldsymbol{\mu}) \xrightarrow{d} N(\mathbf{0}, \boldsymbol{\Sigma})$ 。

## 6.4 使用蒙特卡罗法模拟中心极限定理

使用蒙特卡罗法来模拟中心极限定理。

假设  $x$  服从在  $(0, 1)$  上的均匀分布，从此分布随机抽取观测值，

样本容量为 30，希望用蒙特卡罗法直观地“看到”样本均值  $\bar{x}_{30}$  的分布，并与正态分布相比较。

从  $(0, 1)$  上的均匀分布抽取 10000 个样本容量为 30 的随机样本，得到 10000 个  $\bar{x}_{30}$  的观测值，然后画其直方图。

可使用如下 Stata 程序：

首先，用命令 `program` 定义一个叫“`onesample`”的程序，从均匀分布抽取一个样本容量为 30 的随机样本，并计算  $\bar{x}_{30}$ ；

其次，用命令 `simulate` 重复此程序 10000 次，得到 10000 个  $\bar{x}_{30}$  的观测值；

最后，用命令 `histogram` 画  $\bar{x}_{30}$  的直方图。

可在 Stata 命令窗口依次输入如下命令：

```
. program onesample, rclass      (定义程序 onesample,
并以 r() 形式储存结果)
    drop _all                    (删去内存中已有数据)
    set obs 30                   (确定随机抽样的样本容量为 30)
```

```
gen x=runiform()      (得到在(0,1)上均匀分布的随机样本)
sum x                  (使用命令 sum 计算样本均值)
return scalar mean_sample=r(mean) (将样本均值记
为 mean_sample)
end                    (程序 onesample 结束)
```

```
. set more off          (指定 Stata 输出结果连续翻页)
```

```
. simulate xbar=r(mean_sample),seed(101)
reps(10000) nodots: onesample
```

选择项 “reps(10000)” 表示，命令 `simulate` 将运行 “onesample” 程序 10000 遍，并生成变量 `xbar` 来记录这 10000 个样本均值。

选择项“`seed(101)`”用来确定随机数的初始值，以便再次模拟或别人运行此程序时，也能得到完全一样的结果。

选择项“`nodots`”表示不显示表示模拟过程的点点(默认以一个点表示抽取一个样本)。

```
. hist xbar,normal
```

选择项“`normal`”表示画出相应的正态分布，结果参见图 6.7。




图 6.7 模拟中心极限定理

虽然样本容量仅为 30，但  $\bar{x}_{30}$  的分布已经很接近于正态分布。

作为练习，可从  $\chi^2(10)$  中抽取随机样本，重复上面的蒙特卡罗模拟。

只要将上面程序中的语句 “`gen x=runiform()`” 改为 “`gen x=rchi2(10)`” 即可。

## 6.5 统计量的大样本性质

在大样本理论下，我们关心当样本容量  $n \rightarrow \infty$  时，统计量是否具有良好的大样本性质。

## 1. 一致估计量

**定义** 考虑参数  $\beta$  的估计量  $\hat{\beta}_n$ ，其中下标  $n$  为样本容量(强调  $\hat{\beta}_n$  对样本容量  $n$  依赖)。如果  $\text{plim}_{n \rightarrow \infty} \hat{\beta}_n = \beta$ ，则称  $\hat{\beta}_n$  是参数  $\beta$  的一致估计量(consistent estimator)。

一致性(consistency)意味着，当样本容量足够大时， $\hat{\beta}_n$  依概率收敛到真实参数  $\beta$ ，参见图 6.8。

这是对估计量最基本，也是最重要的要求。

如果估计方法不一致，则意味着研究没有太大意义；因为无论样本容量多大，估计量也不会收敛到真实值。






图 6.8 一致估计量示意图

在多维情况下，称估计量  $\hat{\boldsymbol{\beta}}_n$  是参数  $\boldsymbol{\beta}$  的一致估计量，如果  $\text{plim}_{n \rightarrow \infty} \hat{\boldsymbol{\beta}}_n = \boldsymbol{\beta}$ ，即  $\hat{\boldsymbol{\beta}}_n$  的各分量都是  $\boldsymbol{\beta}$  相应分量的一致估计。

## 2. 渐近正态分布与渐近方差

定义 如果  $\sqrt{n}(\hat{\beta}_n - \beta) \xrightarrow{d} N(0, \sigma^2)$ ，则称  $\hat{\beta}_n$  为渐近正态 (asymptotically normal)，称  $\sigma^2$  为其渐近方差 (asymptotic variance)，记为  $\text{Avar}(\hat{\beta}_n)$ 。

可近似认为  $\hat{\beta}_n \xrightarrow{d} N(\beta, \sigma^2/n)$ ，但不严格 (因为  $\sigma^2/n$  趋于 0)。

在多维情况下，如果  $\sqrt{n}(\hat{\boldsymbol{\beta}}_n - \boldsymbol{\beta}) \xrightarrow{d} N(\mathbf{0}, \boldsymbol{\Sigma})$ ，其中  $\boldsymbol{\Sigma}$  为半正定矩阵，则称  $\hat{\boldsymbol{\beta}}_n$  为渐近正态分布，而称  $\boldsymbol{\Sigma}$  为  $\hat{\boldsymbol{\beta}}_n$  的渐近协方差矩阵，记为  $\text{Avar}(\hat{\boldsymbol{\beta}}_n)$ 。

### 3. 渐近有效

假设  $\hat{\beta}_n$  与  $\tilde{\beta}_n$  都是  $\beta$  的渐近正态估计量。如果  $\text{Avar}(\hat{\beta}_n) \leq \text{Avar}(\tilde{\beta}_n)$ ，则称  $\hat{\beta}_n$  比  $\tilde{\beta}_n$  更为渐近有效(asymptotically more efficient)。

这意味着，在大样本下， $\hat{\beta}_n$  的方差小于  $\tilde{\beta}_n$  的方差(尽管在小样本下未必如此)。

在多维情况下，假设 $\hat{\boldsymbol{\beta}}_n$ 与 $\tilde{\boldsymbol{\beta}}_n$ 都是 $\boldsymbol{\beta}$ 的渐近正态估计量。如果 $[\text{Avar}(\tilde{\boldsymbol{\beta}}_n) - \text{Avar}(\hat{\boldsymbol{\beta}}_n)]$ 为半正定矩阵，则称 $\hat{\boldsymbol{\beta}}_n$ 比 $\tilde{\boldsymbol{\beta}}_n$ 更为渐近有效。

## 6.6 随机过程的性质

大数定律与中心极限定理假设随机序列为独立同分布(iid)，但对于大多数经济变量而言，此假定可能太强了。

比如，今年的通货膨胀率通常依赖于去年的通货膨胀率，二者并非相互独立。

我们需要研究随机序列的性质，并将常规的大数定律与中心极限定理进行推广。

随机序列 $\{x_n\}_{n=1}^{\infty}$ 也称为随机过程(stochastic process)。如果下标为时间，则记为 $\{x_t\}_{t=1}^{\infty}$ ，也称时间序列(time series)。

## 1. 严格平稳过程

数据集 `price_retail.dta` 包含中国 1978-2021 年的通货膨胀率数据(商品零售价格指数，上年=100)，可记为 $\{\pi_{1978}, \pi_{1979}, \dots, \pi_{2021}\}$ 。

打开此数据集，并画其时间趋势图：

```
. use price_retail.dta, clear  
. graph twoway connect price year,  
ylines(100, lp(dash))
```

选择项“`ylines(100, lp(dash))`”指定在纵轴等于 100 的位置画一条水平的虚线，结果参见图 6.9。




图 6.9 中国商品零售价格指数(上年=100)

数据来源：国家统计局网站(<http://data.stats.gov.cn>)

假如每年的通货膨胀率作为一个随机变量都有自己不同的分布，如何估计 $E(\pi_{1978})$ 与 $\text{Var}(\pi_{1978})$ ？

每年通货膨胀率的样本容量仅为 1，且历史不能重演(也无法穿越)！

如果这 44 年的通货膨胀率分布都不变，则可将 $\bar{\pi} \equiv \frac{1}{44} \sum_{t=1978}^{2021} \pi_t$ 作为 $E(\pi_t)$ 的估计量。

通常要求随机过程 $\{x_t\}_{t=1}^{\infty}$ 的概率分布不随时间推移而改变。

无论过去、现在还是未来去看此随机过程，它的概率分布性质都一样。

这种随机过程称为“严格平稳过程”，它要求随机过程的有限维分布不随时间推移而改变。

比如， $x_t$  的分布与  $x_s$  的分布相同 ( $\forall t, s$ )。

$(x_1, x_4)$  的分布与  $(x_2, x_5)$  相同 (二者均相隔 3 期)。

$(x_1, x_2, x_3)$  的分布与  $(x_5, x_6, x_7)$  相同 (二者均为连续 3 期)。

**定义** 随机过程  $\{x_t\}_{t=1}^{\infty}$  是 **严格平稳过程** (strictly stationary process)，简称平稳过程，如果对任意  $m$  个时期的时间集合  $\{t_1, t_2, \dots, t_m\}$ ，随机向量  $\{x_{t_1}, x_{t_2}, \dots, x_{t_m}\}$  的联合分布等于随机向量  $\{x_{t_1+k}, x_{t_2+k}, \dots, x_{t_m+k}\}$  的联合分布，其中  $k$  为任意整数。



这意味着，将  $\{x_{t_1}, x_{t_2}, \dots, x_{t_m}\}$  中每个变量的时间下标全部前移或后移  $k$  期，不会改变其分布。

$\{x_{t_1}, x_{t_2}, \dots, x_{t_m}\}$  的联合分布仅取决于  $\{t_1, t_2, \dots, t_m\}$  各个时期之间的相对距离，而不依赖于其绝对位置。

**例** 如果随机过程  $\{x_t\}_{t=1}^{\infty}$  为 iid，则  $\{x_t\}_{t=1}^{\infty}$  是平稳过程，且不存在序列相关。

**例** 如果随机过程  $\{x_t\}_{t=1}^{\infty} = \{x_1, x_1, x_1, \dots\}$  (即  $x_t \equiv x_1$ )，则  $\{x_t\}_{t=1}^{\infty}$  是平稳过程，且存在最强的序列相关。

例 考虑以下一阶自回归过程(AR(1)),

$$y_t = \rho y_{t-1} + \varepsilon_t \quad (t = 1, \dots, T) \quad (6.9)$$

其中,  $\{\varepsilon_t\}$  为独立同分布, 且  $\text{Cov}(y_{t-1}, \varepsilon_t) = 0$ 。

**命题** 如果  $\rho = 1$ , 则  $\{y_t\}$  不是平稳过程。如果  $|\rho| < 1$ , 则  $\{y_t\}$  为平稳过程。

**证明:** 如果  $\rho = 1$ , 则  $y_t = y_{t-1} + \varepsilon_t$ 。因此,  $y_1 = y_0 + \varepsilon_1$ , 而  $y_2 = y_1 + \varepsilon_2 = y_0 + \varepsilon_1 + \varepsilon_2$ , 以此类推可知

$$y_t = y_0 + \varepsilon_1 + \varepsilon_2 + \dots + \varepsilon_t \quad (6.10)$$

给定初始值  $y_0$ ，当  $t \rightarrow \infty$  时， $\text{Var}(y_t) = t\sigma_\varepsilon^2 \rightarrow \infty$ ，其中  $\sigma_\varepsilon^2 \equiv \text{Var}(\varepsilon_t)$ ，即方差越来越大，以至无穷。

因此， $\{y_t\}$  不是平稳过程(平稳过程要求同分布，故方差不变)。

由于  $y_t$  只是在  $y_{t-1}$  的基础上，加上一个随机扰动项  $\varepsilon_t$ ，故当  $\rho = 1$  时，称  $\{y_t\}$  为“随机游走”(random walk)。

如果  $|\rho| < 1$ ，则  $\text{Var}(y_t)$  会收敛到常数。对方程(6.9)两边同时取方差，可得

$$\text{Var}(y_t) = \rho^2 \text{Var}(y_{t-1}) + \sigma_\varepsilon^2 \quad (6.11)$$

记  $z_t \equiv \text{Var}(y_t)$ ， $z_{t-1} = \text{Var}(y_{t-1})$ ，则上式可写为

$$z_t = \rho^2 z_{t-1} + \sigma_\varepsilon^2 \quad (6.12)$$

这是确定性的一阶线性差分方程，因为  $z_t \equiv \text{Var}(y_t)$  为非随机。

由于  $\rho^2 < 1$ ，故  $\text{Var}(y_t)$  将收敛到一个稳定值，参见图 6.10。

在方程(6.12)中，令  $z_t = z_{t-1}$ ，可求解此收敛的稳定值  $z^*$ ：

$$z^* = \rho^2 z^* + \sigma_\varepsilon^2 \quad (6.13)$$

整理后可得， $z^* = \frac{\sigma_\varepsilon^2}{1 - \rho^2}$ 。如果忽略序列  $\{y_t\}$  的前面几项，则可

将  $\{y_t\}$  的方差视为常数。进一步可证明， $\{y_t\}_{t=0}^\infty$  是严格平稳过程。




图 6.10 平稳一阶自回归过程的方差收敛

有时我们仅仅关心随机过程的期望、方差及协方差是否稳定，而不要求整个分布都稳定，故引入以下“弱平稳过程”的概念。

**定义** 随机过程 $\{x_t\}_{t=1}^{\infty}$ 是弱平稳过程(weakly stationary process)或协方差平稳过程(covariance stationary process)，如果 $E(x_t)$ 不依赖于 $t$ ，而且 $\text{Cov}(x_t, x_{t+k})$ 仅依赖于 $k$  (即 $x_t$ 与 $x_{t+k}$ 在时间上的相对距离)而不依赖于其绝对位置 $t$ 。

对于弱平稳过程，由于 $E(x_t)$ 不依赖于 $t$ ，故其期望为常数。

由于 $\text{Cov}(x_t, x_{t+k})$ 仅依赖于 $k$ ，如果令 $k=0$ ，则 $\text{Cov}(x_t, x_t) = \text{Var}(x_t)$ 也不依赖于 $t$ ，故弱平稳过程的方差也是常数。

严格平稳过程是弱平稳过程的充分条件；但反之则不然，因为弱平稳过程只要求二阶矩平稳(即期望、方差、协方差等不随时间而变)，而概率分布还可能依赖于更高阶的矩。

在实践中较常用的弱平稳过程是期望为 0，且不存在序列相关的白噪声过程。

**定义** 对于弱平稳过程  $\{x_t\}_{t=1}^{\infty}$ ，如果对于  $\forall t$ ，都有  $E(x_t) = 0$ ，而且  $\text{Cov}(x_t, x_{t+k}) = 0$  ( $\forall k \neq 0$ )，则称为白噪声过程(white noise process)。

白噪声过程不一定独立同分布，也不一定是严格平稳过程。

“白噪声”是性质比较好的“噪声”，即该噪声的期望值为 0，而不同期之间的噪声互不相关。

对于随机向量过程  $\{\mathbf{x}_t\}_{t=1}^{\infty}$ ，可以类似地定义平稳过程或弱平稳过程(只要将上述定义中的  $x$  替换为  $\mathbf{x}$  即可)。

如果  $\{\mathbf{x}_t\}_{t=1}^{\infty}$  为(弱)平稳过程，则其每个分量都是(弱)平稳过程；反之，则不然。

## 2. 渐近独立性

“严格平稳过程”(相当于“同分布”假定)还不足以应用大数定律或中心极限定理，因为它们都要求独立同分布(iid)。



但“相互独立”的假定对于大多数经济变量而言过强了。

比如，今年的通胀率显然与去年的通胀率相关。

但今年的通胀率与 100 年前的通胀率或许可近似地视为相互独立，称为**渐近独立**(ergodic，也称**遍历性**)，或**弱相依**(weakly dependent)。

渐近独立意味着，只要两个随机变量相距足够远，可近似认为它们相互独立。

**例** 相互独立的随机序列是渐近独立的。

例 AR(1)是否渐近独立？考虑以下一阶自回归模型：

$$y_t = \rho y_{t-1} + \varepsilon_t \quad (6.14)$$

其中， $|\rho| < 1$ ，而 $\varepsilon_t$ 为白噪声。

为考察其渐近独立性，分别计算其各阶“自协方差” (autocovariance)。当时间间隔为 1 期时，一阶自协方差为

$$\text{Cov}(y_t, y_{t-1}) = \text{Cov}(\rho y_{t-1} + \varepsilon_t, y_{t-1}) = \rho \sigma_y^2 + \underbrace{\text{Cov}(\varepsilon_t, y_{t-1})}_{=0} = \rho \sigma_y^2 \quad (6.15)$$

其中， $\sigma_y^2$ 为  $y$  的方差，而

$\text{Cov}(\varepsilon_t, y_{t-1}) = \text{Cov}(\varepsilon_t, \rho y_{t-2} + \varepsilon_{t-1}) = \text{Cov}(\varepsilon_t, \varepsilon_{t-1}) = 0$ , 因为  $\varepsilon_t$  为白噪声(无序列相关)。

当时间间隔为 2 期时, 原方程(6.14)可写为

$$y_t = \rho y_{t-1} + \varepsilon_t = \rho(\rho y_{t-2} + \varepsilon_{t-1}) + \varepsilon_t = \rho^2 y_{t-2} + \rho \varepsilon_{t-1} + \varepsilon_t \quad (6.16)$$

因此, 二阶自协方差为

$$\text{Cov}(y_t, y_{t-2}) = \text{Cov}(\rho^2 y_{t-2} + \rho \varepsilon_{t-1} + \varepsilon_t, y_{t-2}) = \rho^2 \sigma_y^2 \quad (6.17)$$

以此类推, 当时间间隔为  $j$  期时,

$$\text{Cov}(y_t, y_{t-j}) = \rho^j \sigma_y^2 \quad (6.18)$$

由于 $|\rho| < 1$ ，故当上式 $j \rightarrow \infty$ 时， $\text{Cov}(y_t, y_{t-j}) \rightarrow 0$ 。

相距越远，则序列 $\{y_t\}$ 的自协方差越小，且在极限处变为 0(不相关)，故此 AR(1)模型为渐近独立的过程。

有了严格平稳过程与渐近独立的概念后，可将大数定律作以下重要推广。

**渐近独立定理(Ergodic Theorem)** 假设 $\{x_i\}_{i=1}^{\infty}$ 为渐近独立的严格平稳过程，且 $E(x_i) = \mu$ 存在，则 $\bar{x}_n \equiv \frac{1}{n} \sum_{i=1}^n x_i \xrightarrow{p} \mu$ ，即样本均值 $\bar{x}_n$ 是总体均值 $E(x_i)$ 的一致估计。

渐近独立定理是对大数定律的重要推广，更适用于经济数据。

大数定律要求每个  $x_i$  相互独立，而渐近独立定理允许  $\{x_i\}_{i=1}^{\infty}$  存在“序列相关” (serial correlation)，只要此相关关系在极限处消失即可。

大数定律要求每个  $x_i$  的分布相同，而渐近独立定理要求  $\{x_i\}_{i=1}^{\infty}$  为严格平稳过程，故也是同分布的。

类似地，可将中心极限定理作相应的推广；即在一定条件下，中心极限定理也适用于渐近独立的平稳过程。

**命题** 如果  $\{x_i\}_{i=1}^{\infty}$  为渐近独立的严格平稳过程，则对于任何连续函数  $f(\cdot)$ ， $\{y_i \equiv f(x_i)\}_{i=1}^{\infty}$  也是渐近独立的严格平稳过程。

根据此命题，则渐近独立定理意味着，只要  $f(\cdot)$  为连续函数，则渐近独立平稳过程  $\{x_i\}_{i=1}^{\infty}$  的任何总体矩 (population moment)  $E[f(x_i)]$ ，都可以由其对应的样本矩 (sample moment)  $\frac{1}{n} \sum_{i=1}^n f(x_i)$  来一致地估计。

例 对于渐近独立的平稳过程  $\begin{pmatrix} x_i \\ y_i \end{pmatrix}_{i=1}^{\infty}$ ，样本方差

$s^2 \equiv \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$  是总体方差  $\text{Var}(x) \equiv E[x - E(x)]^2$  的一致估计；

而样本协方差  $s_{xy} \equiv \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$  为总体协方差

$\text{Cov}(x, y) \equiv E[(x - E(x))(y - E(y))]$  的一致估计。

## 6.7 大样本 OLS 的假定

假定 6.1 线性假定

$$y_i = \beta_1 + \beta_2 x_{i2} + \cdots + \beta_K x_{iK} + \varepsilon_i \quad (i = 1, \cdots, n) \quad (6.19)$$

**假定 6.2**  $(K + 1)$ 维随机过程 $\{y_i, x_{i1}, \dots, x_{iK}\}$ 为渐近独立的平稳过程(ergodic stationarity), 故适用大数定律与中心极限定理。

**例** 如果样本为随机样本, 则 $\{y_i, x_{i1}, \dots, x_{iK}\}$ 独立同分布, 故是渐近独立的平稳过程。

**假定 6.3** 前定解释变量(predetermined regressors)

所有解释变量均为前定(predetermined), 也称同期外生(contemporaneously exogenous), 即它们与同期(同方程)的扰动项正交, 即 $E(x_{ik}\varepsilon_i) = 0, \forall i, k$ 。

由于 $E(x_{ik}\varepsilon_i) = 0$ , 故 $x_{ik}$ 与 $\varepsilon_i$ 不相关, 仿佛在 $\varepsilon_i$ 产生之前,  $x_{ik}$ 已经确定, 故名“前定解释变量”。



此假定比严格外生性假定更弱，因为后者要求扰动项与过去、现在及未来的解释变量都不相关(对于时间序列数据而言)，而前定变量仅要求与同期的扰动项不相关。

#### 假定 6.4 秩条件(rank condition)

数据矩阵  $\mathbf{X}$  满列秩，即  $\mathbf{X}$  中没有多余(可由其他变量线性表出)的解释变量。

大样本理论的假定 6.1 与 6.4 与小样本理论相同，而假定 6.2 与 6.3 则比小样本理论更为放松。

大样本 OLS 无须假设“严格外生性”与“正态随机扰动项”，故具有更大的适用性与稳健性。

## 6.8 OLS 的大样本性质

在假定 6.1-6.4 之下，可以证明 OLS 估计量  $\hat{\beta}$  具有以下良好的大样本性质。

(1)  $\hat{\beta}$  为一致估计量，即  $\text{plim}_{n \rightarrow \infty} \hat{\beta} = \beta$ ；

以一元回归为例进行说明。考虑以下模型：

$$y_i = \alpha + \beta x_i + \varepsilon_i \quad (i = 1, \dots, n) \quad (6.20)$$

其中， $\beta$  的 OLS 估计量为(参见第 4 章)

$$\hat{\beta} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} \quad (6.21)$$

此模型的离差形式为(参见习题)

$$y_i - \bar{y} = \beta(x_i - \bar{x}) + (\varepsilon_i - \bar{\varepsilon}) \quad (6.22)$$

其中,  $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$ ,  $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ , 而  $\bar{\varepsilon} = \frac{1}{n} \sum_{i=1}^n \varepsilon_i$ 。

将方程(6.22)代入原方程(6.20)可得

$$\begin{aligned}
\hat{\beta} &= \frac{\sum_{i=1}^n (x_i - \bar{x}) [\beta(x_i - \bar{x}) + (\varepsilon_i - \bar{\varepsilon})]}{\sum_{i=1}^n (x_i - \bar{x})^2} \\
&= \frac{\beta \sum_{i=1}^n (x_i - \bar{x})^2 + \sum_{i=1}^n (x_i - \bar{x})(\varepsilon_i - \bar{\varepsilon})}{\sum_{i=1}^n (x_i - \bar{x})^2} \\
&= \beta + \frac{\sum_{i=1}^n (x_i - \bar{x})(\varepsilon_i - \bar{\varepsilon})}{\sum_{i=1}^n (x_i - \bar{x})^2} \\
&= \beta + \frac{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(\varepsilon_i - \bar{\varepsilon})}{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2} \xrightarrow{p} \beta + \underbrace{\frac{\text{Cov}(x_i, \varepsilon_i)}{\text{Var}(x_i)}}_{=0} = \beta
\end{aligned}$$

(6.23)

其中，根据假定 6.3， $\text{Cov}(x_i, \varepsilon_i) = 0$ 。

前定解释变量，或扰动项与解释变量同期不相关，是保证 OLS 一致的最重要条件。

反之，如果  $\text{Cov}(x_i, \varepsilon_i) \neq 0$ ，则  $\text{plim}_{n \rightarrow \infty} \hat{\beta} = \beta + \frac{\text{Cov}(x_i, \varepsilon_i)}{\text{Var}(x_i)} \neq \beta$ 。

如果  $\text{Cov}(x_i, \varepsilon_i) > 0$ ，则  $\text{plim}_{n \rightarrow \infty} \hat{\beta} > \beta$ 。比如，考察教育投资的回报率， $x_i$  为教育年限，而  $\varepsilon_i$  为被遗漏的个人能力。

$x_i$ 与 $\varepsilon_i$ 正相关(能力高者通常上学更久),故 OLS 估计量将高估教育投资的回报率。

如果 $\text{Cov}(x_i, \varepsilon_i) < 0$ , 则 $\text{plim}_{n \rightarrow \infty} \hat{\beta} < \beta$ 。比如, 考察上医院对健康的作用,  $x_i$ 为是否上医院, 而 $\varepsilon_i$ 为个人原来的健康状况(被遗漏)。

$x_i$ 与 $\varepsilon_i$ 负相关(通常只有健康不佳者才上医院),故 OLS 估计量将低估上医院对健康的正面作用(去医院者的健康往往不如未去医院者)。

可通过图示来考察 $\text{Cov}(x_i, \varepsilon_i) \neq 0$ 的后果, 参见图 6.11。




图 6.11 扰动项与解释变量相关导致不一致估计

如果解释变量与扰动项相关，即  $\text{Cov}(x_i, \varepsilon_i) \neq 0$ ，则称此解释变量为**内生解释变量**(endogenous regressor)，简称“**内生变量**”；反之，则为**外生变量**(exogenous variable)。

由于内生变量的存在，致使 OLS 回归出现偏差，统称为**内生性偏差**(endogeneity bias)，简称**内生性**。

在什么情况下可能出现内生性偏差？

如果存在遗漏变量、双向因果关系、或解释变量测量误差(measurement errors)，则常会出现解释变量与扰动项同期相关的情形，导致 OLS 不一致。



(2)  $\hat{\boldsymbol{\beta}}$  服从渐近正态分布, 即  $\sqrt{n}(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}) \xrightarrow{d} N(\mathbf{0}, \text{Avar}(\hat{\boldsymbol{\beta}}))$ , 其中  $\text{Avar}(\hat{\boldsymbol{\beta}})$  为  $\hat{\boldsymbol{\beta}}$  的渐近协方差矩阵。

$\hat{\boldsymbol{\beta}}$  之所以服从渐近正态, 是因为在一定条件下, 中心极限定理适用于渐近独立的平稳过程。

(3) 由于大样本理论一般不假设球形扰动项, 故渐近协方差矩阵  $\text{Avar}(\hat{\boldsymbol{\beta}})$  的表达式更为复杂。

根据第 5 章公式(5.46), OLS 估计量  $\hat{\boldsymbol{\beta}}$  的协方差矩阵可写为夹心估计量的形式:

$$\text{Var}(\hat{\boldsymbol{\beta}} | \mathbf{X}) = (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}' \text{Var}(\boldsymbol{\varepsilon} | \mathbf{X}) \mathbf{X} (\mathbf{X}'\mathbf{X})^{-1} \quad (6.24)$$

其中,  $\text{Var}(\boldsymbol{\varepsilon} | \mathbf{X})$ 为扰动项的协方差矩阵。

如果存在球形扰动项(同方差、无自相关), 则 $\text{Var}(\boldsymbol{\varepsilon} | \mathbf{X}) = \sigma^2 \mathbf{I}_n$ , 上式可简化为

$$\text{Var}(\hat{\boldsymbol{\beta}} | \mathbf{X}) = (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'(\sigma^2 \mathbf{I}_n) \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} = \sigma^2 (\mathbf{X}'\mathbf{X})^{-1} \quad (6.25)$$

对于横截面数据, 经常存在异方差, 但无自相关(比如, 各截面单位之间相互独立), 扰动项的协方差矩阵可写为

$$\text{Var}(\boldsymbol{\varepsilon} | \mathbf{X}) = \begin{pmatrix} \sigma_1^2 & & 0 \\ & \ddots & \\ 0 & & \sigma_n^2 \end{pmatrix} \quad (6.26)$$

其中,  $\sigma_1^2, \dots, \sigma_n^2$  不全相等。

如何估计上式的  $\{\sigma_1^2, \dots, \sigma_n^2\}$ ?

由于  $\{\sigma_1^2, \dots, \sigma_n^2\}$  为各扰动项的方差, 且  $\sigma_i^2 = \text{Var}(\varepsilon_i) = \underbrace{E(\varepsilon_i^2) - [E(\varepsilon_i)]^2}_{=0} = E(\varepsilon_i^2)$ , 故一个自然想法是, 以 OLS 残差平方  $\{e_1^2, \dots, e_n^2\}$  替代上式的  $\{\sigma_1^2, \dots, \sigma_n^2\}$ , 得到扰动项协方差矩阵的估计量:

$$\widehat{\text{Var}(\boldsymbol{\varepsilon} | \mathbf{X})} = \frac{n}{n-K} \begin{pmatrix} e_1^2 & & 0 \\ & \ddots & \\ 0 & & e_n^2 \end{pmatrix} \quad (6.27)$$

其中,  $\frac{n}{n-K}$  为自由度的调整(在大样本下无差别)。

将表达式(6.27)代入方程(6.24), 可得如下方差估计量

$$\widehat{\text{Var}}(\hat{\boldsymbol{\beta}} | \mathbf{X}) = (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}' \widehat{\text{Var}}(\boldsymbol{\varepsilon} | \mathbf{X}) \mathbf{X} (\mathbf{X}'\mathbf{X})^{-1} \quad (6.28)$$

上式只在小样本下才成立。

当  $n \rightarrow \infty$  时, 对参数  $\hat{\boldsymbol{\beta}}$  的估计变得无限准确, 故  $\widehat{\text{Var}}(\hat{\boldsymbol{\beta}} | \mathbf{X}) \rightarrow 0$ 。

考虑  $\sqrt{n} \hat{\boldsymbol{\beta}}$  的方差估计量, 即  $\hat{\boldsymbol{\beta}}$  的渐近方差估计量:

$$\widehat{\text{Avar}}(\hat{\boldsymbol{\beta}} | \mathbf{X}) = n(\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}' \widehat{\text{Var}}(\boldsymbol{\varepsilon} | \mathbf{X}) \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} \quad (6.29)$$

上式为 $\hat{\boldsymbol{\beta}}$ 渐近协方差矩阵的一致估计量，即

$$\widehat{\text{Avar}}(\hat{\boldsymbol{\beta}} | \mathbf{X}) \xrightarrow{p} \text{Avar}(\hat{\boldsymbol{\beta}} | \mathbf{X}) \quad (6.30)$$

由于在推导过程中并未假设“条件同方差”，故它提供了在“条件异方差”情况下也成立的标准误，称为异方差稳健的标准误(heteroskedasticity-consistent standard errors)，简称稳健标准误(robust standard errors)。

在形式上，稳健标准误也是夹心估计量。

稳健标准误的思想最早由 Eicker (1967)与 Huber (1967)提出，并由 White (1980)严格证明，故也称 White's standard errors, Huber-White standard errors, 或 Eicker-Huber-White standard errors。

通过使用迭代期望定律可以证明，在条件同方差的假定下，稳健标准误还原为普通(非稳健)标准误。

特别地，考虑同方差的一种极端情形，即  $e_1^2 = e_2^2 = \cdots = e_n^2$  (所有残差的绝对值都相等，但符号可以相反)，则

$$\widehat{\text{Var}}(\boldsymbol{\varepsilon} | \mathbf{X}) = \frac{n}{n-K} \begin{pmatrix} e_1^2 & & 0 \\ & \ddots & \\ 0 & & e_n^2 \end{pmatrix} = \frac{ne_i^2}{n-K} \mathbf{I}_n = \underbrace{\frac{\sum_{i=1}^n e_i^2}{n-K}}_{=s^2} \mathbf{I}_n = s^2 \mathbf{I}_n \quad (6.31)$$

此时，稳健的协方差矩阵可简化为同方差情况下的普通(非稳健)协方差矩阵：

$$\begin{aligned} \widehat{\text{Var}}(\hat{\boldsymbol{\beta}} | \mathbf{X}) &= (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}' \widehat{\text{Var}}(\boldsymbol{\varepsilon} | \mathbf{X}) \mathbf{X} (\mathbf{X}'\mathbf{X})^{-1} \\ &= (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}' (s^2 \mathbf{I}_n) \mathbf{X} (\mathbf{X}'\mathbf{X})^{-1} = s^2 (\mathbf{X}'\mathbf{X})^{-1} \end{aligned} \quad (6.32)$$

## 6.9 大样本统计推断

对于渐近独立的平稳过程，如果样本容量足够大，则 OLS 估计量  $\hat{\boldsymbol{\beta}}$  的渐近正态分布是对其真实分布的较好近似，故可使用其渐近分布进行大样本假设检验与区间估计。

### 1. 检验单个系数： $H_0 : \beta_k = c$

考虑检验  $H_0 : \beta_k = c$ ，其中  $c$  为已知常数。

根据大样本理论，OLS 估计量  $\hat{\boldsymbol{\beta}}$  服从渐近正态分布，即  $\sqrt{n}(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}) \xrightarrow{d} N(\mathbf{0}, \text{Avar}(\hat{\boldsymbol{\beta}}))$ ，其中  $\text{Avar}(\hat{\boldsymbol{\beta}})$  为渐近协方差矩阵。



具体到 $\hat{\boldsymbol{\beta}}$ 的第  $k$  个元素  $\hat{\beta}_k$ ，则有

$$\sqrt{n}(\hat{\beta}_k - \beta_k) \xrightarrow{d} N(0, \text{Avar}(\hat{\beta}_k)) \quad (6.33)$$

其中， $\text{Avar}(\hat{\beta}_k)$  为  $\hat{\beta}_k$  的渐近方差，即渐近方差矩阵  $\text{Avar}(\hat{\boldsymbol{\beta}})$  主对角线上的第  $k$  个元素。

在原假设  $H_0$  成立的情况下， $\beta_k = c$ ，故表达式(6.33)可写为

$$\sqrt{n}(\hat{\beta}_k - c) \xrightarrow{d} N(0, \text{Avar}(\hat{\beta}_k)) \quad (6.34)$$

记  $\widehat{\text{Avar}}(\hat{\beta}_k)$  为渐近方差矩阵估计量  $\widehat{\text{Avar}}(\hat{\beta})$  主对角线上的第  $k$  个元素，则  $\widehat{\text{Avar}}(\hat{\beta}_k)$  是  $\text{Avar}(\hat{\beta}_k)$  的一致估计量。

定义  $t$  统计量为

$$t_k \equiv \frac{\sqrt{n}(\hat{\beta}_k - c)}{\sqrt{\widehat{\text{Avar}}(\hat{\beta}_k)}} = \frac{\hat{\beta}_k - c}{\sqrt{\frac{1}{n}\widehat{\text{Avar}}(\hat{\beta}_k)}} \equiv \frac{\hat{\beta}_k - c}{\text{SE}^*(\hat{\beta}_k)} \xrightarrow{d} N(0, 1) \quad (6.35)$$

$\text{SE}^*(\hat{\beta}_k) \equiv \sqrt{\frac{1}{n}\widehat{\text{Avar}}(\hat{\beta}_k)}$  即为异方差稳健的标准误。

由于在推导过程中并未用到“条件同方差”的假定，故在“条件异方差”的情况下也适用。

统计量 $t_k$ 称为稳健 $t$ 比值(robust  $t$  ratio), 服从渐近标准正态分布, 而不是 $t$ 分布。

对于双边检验(即  $H_1 : \beta_k \neq c$ ), 则 $|t_k|$ 越大, 越倾向于拒绝 $H_0$ 。

比如, 对于 5% 的显著性水平, 如果 $|t_k|$ 大于临界值 1.96, 则可拒绝 $H_0$ 。

也可通过  $p$  值进行检验, 其方法与小样本理论相同(参见第 5 章)。

## 2. 检验线性假设: $H_0 : \mathbf{R}\boldsymbol{\beta} = \mathbf{r}$

在大样本理论下, 对于多个线性假设的联合检验, 与小样本理论下的  $F$  检验类似。考虑检验  $m$  个线性假设是否同时成立:

$$H_0 : \underbrace{\mathbf{R}}_{m \times K} \underbrace{\boldsymbol{\beta}}_{K \times 1} = \underbrace{\mathbf{r}}_{m \times 1}$$

其中， $\mathbf{r}$  为  $m$  维列向量 ( $m < K$ )， $\mathbf{R}$  为  $m \times K$  矩阵，且  $\text{rank}(\mathbf{R}) = m$ ，即  $\mathbf{R}$  满行秩，没有多余或自相矛盾的行或方程。

对于原假设  $H_0 : \mathbf{R}\boldsymbol{\beta} = \mathbf{r}$ ，根据沃尔德检验原理，可考察  $(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r})$  的大小，譬如其二次型  $(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r})'(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r})$ 。

在  $H_0$  成立的情况下，可以证明统计量

$$W \equiv n(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r})' [\widehat{\mathbf{R} \text{Avar}(\hat{\boldsymbol{\beta}}) \mathbf{R}'}]^{-1} (\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r}) \xrightarrow{d} \chi^2(m) \quad (6.36)$$

其中， $\widehat{\mathbf{R} \text{Avar}(\hat{\boldsymbol{\beta}}) \mathbf{R}'}$  为  $(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r})$  的渐近方差矩阵(使用夹心估计量公式)。

如果统计量  $W$  大于  $\chi^2(m)$  的临界值，则拒绝原假设。

在表达式(6.36)中，虽然统计量  $W$  服从  $\chi^2$  分布，而非小样本理论下的  $F$  分布，但  $\chi^2$  分布与  $F$  分布在大样本情况下是等价的。

即使在大样本下使用稳健标准误进行假设检验，Stata 也依然汇报  $F$  统计量及其  $p$  值。

命题 假设统计量  $F \sim F(m, n)$  分布，则当  $n \rightarrow \infty$  时，  
 $mF \xrightarrow{d} \chi^2(m)$ 。

证明：因为  $F \sim F(m, n)$ ，故可写为  $F = \frac{\chi^2(m)/m}{\chi^2(n)/n}$ ，其中分子  
与分母相互独立。

根据  $\chi^2$  分布的性质， $\chi^2$  分布的期望等于自由度，而方差等于自  
由度的两倍；即  $E[\chi^2(n)] = n$ ，且  $\text{Var}[\chi^2(n)] = 2n$ 。

考察此  $F$  统计量的分母  $\chi^2(n)/n$ 。

其期望为  $E[\chi^2(n)/n] = n/n = 1$  , 而方差为  $\text{Var}[\chi^2(n)/n] = 2n/n^2 = 2/n \rightarrow 0$  (当  $n \rightarrow \infty$  时)。

因此, 此  $F$  统计量的分母依均方收敛于 1, 故依概率收敛于 1(前者是后者的充分条件), 即  $\chi^2(n)/n \xrightarrow{p} 1$ 。

在大样本下,  $\chi^2(n)/n$  退化为 1, 此  $F$  统计量的性质仅由分子  $\chi^2(m)/m$  决定, 故  $F \xrightarrow{d} \chi^2(m)/m$ 。

因此, 在大样本下,  $mF \xrightarrow{d} \chi^2(m)$ 。

## 6.10 大样本 OLS 的 Stata 实例

在 Stata 中，可方便地得到 OLS 估计的稳健标准误，其命令为

```
. reg y x1 x2 x3, robust
```

选择项 “robust” 表示稳健标准误。

以数据集 nerlove.dta 为例。

取自 Nerlove (1963)对电力行业规模报酬的经典研究。

此数据集包括 1955 年美国 145 家电力企业的横截面数据。



主要变量为  $tc$  (total cost, 总成本),  $q$  (total output, 总产量),  $pl$  (price of labor, 小时工资率),  $pk$  (user cost of capital, 资本的使用成本) 与  $pf$  (price of fuel, 燃料价格), 以及相应的对数值  $lntc$ ,  $lnq$ ,  $lnpl$ ,  $lnpk$ , 与  $lnpf$ 。

Nerlove (1963)假设企业 $i$ 的生产函数为 Cobb-Douglas 函数:

$$Q_i = A_i L_i^{\alpha_1} K_i^{\alpha_2} F_i^{\alpha_3} \quad (6.37)$$

$A, L, K, F$  分别为生产率、劳动力、资本与燃料。

记  $r \equiv \alpha_1 + \alpha_2 + \alpha_3$  为规模效应(degree of returns to scale)。

如果  $r = 1$ , 则规模报酬不变。

如果  $r > 1$ ，则规模报酬递增。

如果  $r < 1$ ，则规模报酬递减。

Nerlove (1963)的主要目的是确定美国电力行业的规模经济。

假设企业追求成本最小化，可以证明成本函数也为 Cobb-Douglas 函数：

$$TC_i = \delta_i Q_i^{1/r} (P_L)_i^{\alpha_1/r} (P_K)_i^{\alpha_2/r} (P_F)_i^{\alpha_3/r} \quad (6.38)$$

$\delta_i$  是  $A_i, \alpha_1, \alpha_2, \alpha_3$  的函数。取对数后得到如下模型，

$$\ln TC_i = \beta_1 + \frac{1}{r} \ln Q_i + \frac{\alpha_1}{r} \ln P_{L,i} + \frac{\alpha_2}{r} \ln P_{K,i} + \frac{\alpha_3}{r} \ln P_{F,i} + \varepsilon_i \quad (6.39)$$

首先, 打开数据集 `nerlove.dta`, 并使用普通标准误对方程(6.39)进行 OLS 估计:

```
. use nerlove.dta, clear
. reg lntc lnq lnpl lnpl lnpl lnpl lnpl
```

Source	SS	df	MS	Number of obs	=	145
Model	269.524728	4	67.3811819	F(4, 140)	=	437.90
Residual	21.5420958	140	.153872113	Prob > F	=	0.0000
				R-squared	=	0.9260
				Adj R-squared	=	0.9239
Total	291.066823	144	2.02129738	Root MSE	=	.39227
lntc	Coefficient	Std. err.	t	P> t	[95% conf. interval]	
lnq	.7209135	.0174337	41.35	0.000	.6864462	.7553808
lnpl	.4559645	.299802	1.52	0.131	-.1367602	1.048689
lnpk	-.2151476	.3398295	-0.63	0.528	-.8870089	.4567136
lnpf	.4258137	.1003218	4.24	0.000	.2274721	.6241554
_cons	-3.566513	1.779383	-2.00	0.047	-7.084448	-.0485779

$R^2 = 0.9260$ ,  $\bar{R}^2 = 0.9239$ , 检验整个方程显著性的  $F$  统计量高达 437.9, 其相应  $p$  值(Prob > F)为 0.0000, 表明此回归方程高度显著。

$\ln pl$  与  $\ln pk$  这两个变量均不显著, 其  $p$  值( $P > |t|$ )分别为 0.131 与 0.528。

变量  $\ln pk$  的系数(Coef.)符号为负, 与经济理论的预测相反。Nerlove(1963)认为, 这是由于“资本使用成本”的数据不太可靠。

由于  $\ln q$  的系数为  $1/r$  (即规模报酬的倒数), 可估计规模报酬为

$$\frac{1}{\text{coef}[\ln q]} = \frac{1}{-0.727129} = -1.387129$$

其中, “ $\text{coef}[\ln q]$ ” 表示 “ $\ln q$ ” 的 OLS 系数估计值。

由于  $\hat{r} = 1.387129 > 1$ ，故认为可能存在规模报酬递增。

为此，检验规模报酬不变的原假设 “ $H_0 : r = 1$ ”，输入命令  
`. test lnq=1`

此命令检验的原假设为，变量  $lnq$  的系数等于 1。

( 1) $lnq = 1$
$F( 1, 140) = 256.27$
Prob > F = 0.0000

由于  $p$  值为 0.0000，故可强烈拒绝原假设，认为存在规模报酬递增。

其次，使用稳健标准误重新进行回归。

`. reg lntc lnq lnpl lnpg lnpr,r`

Linear regression				Number of obs	=	145
				F(4, 140)	=	177.19
				Prob > F	=	0.0000
				R-squared	=	0.9260
				Root MSE	=	.39227
lntc	Coefficient	Robust std. err.	t	P> t	[95% conf. interval]	
lnq	.7209135	.0325376	22.16	0.000	.656585	.785242
lnpl	.4559645	.260326	1.75	0.082	-.0587139	.9706429
lnpk	-.2151476	.3233711	-0.67	0.507	-.8544698	.4241745
lnpf	.4258137	.0740741	5.75	0.000	.2793653	.5722622
_cons	-3.566513	1.718304	-2.08	0.040	-6.963693	-.1693331

对比以上两个回归的结果可知，使用选择项“robust”所得到的 OLS 回归系数完全相同，只是所得到的稳健标准误(Robust Std. Err.)与普通标准误(Std. Err.)不同。

对于变量  $\ln q$  的系数，其稳健标准误(0.033)几乎是普通标准误(0.017)的两倍。

其他变量系数的稳健标准误反而比普通标准误有所下降。

如果认为存在异方差，则应使用稳健标准误。

在异方差的情况下，如果使用普通标准误，将大大低估变量  $\ln q$  系数的真实标准误，从而导致不正确的统计推断。

在 Stata 中使用稳健标准误，即可进行大样本检验。

对单个变量系数显著性的检验，可使用上表中的稳健  $t$  统计量(服从渐近正态分布)来进行。

可直接看表中所列的  $p$  值( $P > |t|$ )。

对于更一般的线性假设，仍可使用命令 `test` 来检验。

比如，检验变量  $\ln q$  的系数是否为 1：

```
. test lnq=1
```

( 1) $\ln q = 1$
$F( 1, 140) = 73.57$
Prob > F = 0.0000

由于  $p$  值为 0.0000，即使使用稳健标准误，仍强烈拒绝原假设。

在使用稳健标准误的情况下，Stata 仍然汇报  $F$  统计量(服从  $F$  分布)，即依然使用小样本理论中的  $F$  统计量公式，但将协方差矩阵换成“稳健的协方差矩阵”。

$F$  分布与  $\chi^2$  分布在大样本下是等价的，参见本章 6.9 节。



## 6.11 大样本理论的蒙特卡罗模拟

考虑以下数据生成过程(DGP):

$$y = \alpha + \beta x + \varepsilon, \quad x \sim \chi^2(1), \quad \varepsilon \sim \chi^2(10) - 10 \quad (6.40)$$

其中,  $\alpha = 1$ ,  $\beta = 2$ , 解释变量  $x$  服从  $\chi^2(1)$  分布; 而扰动项  $\varepsilon$  服从经过位移后的  $\chi^2(10)$  分布, 以保证其期望为零(卡方分布的期望为其自由度); 而且  $x$  与  $\varepsilon$  相互独立。

由于小样本理论要求扰动项服从正态分布, 这个模型不满足小样本理论的假定, 但符合大样本理论的要求。

首先, 考虑样本容量为 20 的情形, 看 OLS 估计量  $\hat{\beta}$  与真实值  $\beta = 2$  的差距, 以及  $\hat{\beta}$  的分布能否收敛到正态分布。

抽取 10000 个样本容量为 20 的随机样本, 进行回归, 得到 10000 个  $\hat{\beta}$ 。

先用命令 `program` 定义一个名为 “`chi2data_20`” 的程序进行一次抽样; 然后, 用命令 `simulate` 来重复此程序 10000 次:

```
. program chi2data_20, rclass (定义程序 chi2data_20,
以 r()形式储存结果)
    drop _all (删去内存中已有数据)
    set obs 20 (确定随机抽样的样本容量为 20)
    gen x = rchi2(1) (生成服从  $\chi^2(1)$  分布的解释变量)
    gen y = 1 + 2*x + rchi2(10)-10 (生成被解释变量)
```

```
reg y x  
return scalar b=_b[x]  
end
```

(线性回归)  
(存储  $\hat{\beta}$  的估计值)  
(程序 chi2data 结束)

```
. set more off
```

(指定 Stata 输出结果连续翻页)

```
. simulate bhat=r(b),reps(10000) seed(10101)  
nodots:chi2data_20
```

其中，选择项 “reps(10000)” 表示通过命令 `simulate` 将程序 “chi2data\_20” 模拟 10000 次。

得到 10000 个  $\hat{\beta}$  后，可计算其均值与标准差：

```
. sum bhat
```

Variable	Obs	Mean	Std. dev.	Min	Max
bhat	10,000	2.007048	.9918413	-6.570165	8.955813

$\hat{\beta}$  的样本均值为 2.0071，很接近真实值 2，验证了  $\hat{\beta}$  为  $\beta$  的无偏估计。

但标准(误)差为 0.992，接近于 1，故估计误差较大(因为样本容量仅为 20)。

通过直方图来看这 10000 个  $\hat{\beta}$  的分布，结果参见图 6.12。

```
. hist bhat,normal
```

其中，选择项 “normal” 表示同时画相应的正态分布密度图。




图 6.12  $\hat{\beta}$  的分布(样本容量为 20)

当样本容量为 20 时,  $\hat{\beta}$  的真实分布与正态分布仍有一定差距。

其次，用命令 `program` 定义一个名为 “`chi2data_100`” 的程序，将样本容量增加至 100(将命令 “`set obs 20`” 改为 “`set obs 100`” )，仍然抽取 10000 个随机样本，即在上述程序中，再次得到 10000 个  $\hat{\beta}$ ；然后看  $\hat{\beta}$  的统计特征。

```
. program chi2data_100,rclass
  drop _all
  set obs 100
  gen x = rchi2(1)
  gen y = 1 + 2*x + rchi2(10)-10
  reg y x
  return scalar b=_b[x]
end
. simulate bhat=r(b),reps(10000) seed(10101)
nodots:chi2data_100
```

```
. sum bhat
```

Variable	Obs	Mean	Std. dev.	Min	Max
bhat	10,000	2.00086	.3378564	.7553486	3.522173

$\hat{\beta}$  的样本均值为 2.00086，更加接近真实值 2。

与当样本容量从 20 增加到 100 后， $\hat{\beta}$  的标准(误)差从 0.992 下降到 0.338。

画  $\hat{\beta}$  的直方图，并与正态分布比较，结果参见图 6.13。

```
. hist bhat,normal
```




图 6.13  $\hat{\beta}$  的分布(样本容量为 100)

当样本容量为 100 时,  $\hat{\beta}$  的真实分布与正态分布已较为接近。



为了进一步验证 OLS 估计量  $\hat{\beta}$  的一致性与渐近正态性，用命令 `program` 定义一个名为 “`chi2data_1000`” 的程序，将样本容量增加为 1000，得到 10000 个  $\hat{\beta}$ ，再看其统计特征。

```
. program chi2data_1000,rclass
  drop _all
  set obs 1000
  gen x = rchi2(1)
  gen y = 1 + 2*x + rchi2(10)-10
  reg y x
  return scalar b=_b[x]
end
. simulate bhat=r(b),reps(10000) seed(10101)
nodots:chi2data_1000
. sum bhat
```

Variable	Obs	Mean	Std. dev.	Min	Max
bhat	10,000	2.000912	.1001662	1.620001	2.440964

当样本容量增加为 1000 时， $\hat{\beta}$  的样本均值为 2.000912；而  $\hat{\beta}$  的标准(误)差则下降为 0.1002。

这验证了  $\hat{\beta}$  依均方收敛于  $\beta$ ，故  $\text{plim}_{n \rightarrow \infty} \hat{\beta} = \beta$ ，即  $\hat{\beta}$  为一致估计量。

通过直方图看  $\hat{\beta}$  的真实分布，参见图 6.14。

```
. hist bhat,normal
```




图 6.14  $\hat{\beta}$  的分布(样本容量为 1000)

当样本容量增加为 1000 时， $\hat{\beta}$  的真实分布已非常接近于正态分布，可以很放心地使用大样本理论进行统计推断。

上述蒙特卡罗模拟验证了 OLS 估计量的一致性与渐近正态性；这些性质即使在扰动项不服从正态分布的情况下也成立，使得大样本理论具有很大的适用性与稳健性。