

## 第 11 章 二值选择模型

### 11.1 二值选择模型

有时被解释变量  $y$  是离散的，而非连续的，称为离散选择模型 (discrete choice model) 或定性反应模型 (qualitative response model)。

最常见的离散选择模型是二值选择行为 (binary choices)。

比如：考研或不考研；就业或待业；买房或不买房；买保险或不买保险；贷款申请被批准或拒绝；出国或不出国；回国或不回

国；战争或和平；生或死。

由于被解释变量为虚拟变量，取值为 0 或 1，故通常不宜进行 OLS 回归。

假设个体只有两种选择，比如  $y = 1$ (考研)或  $y = 0$ (不考研)。

最简单的建模方法为线性概率模型(Linear Probability Model，简称 LPM)：

$$y_i = \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_K x_{iK} + \varepsilon_i = \mathbf{x}_i' \boldsymbol{\beta} + \varepsilon_i \quad (i = 1, \cdots, n)$$

(11.1)

其中，解释变量  $\mathbf{x}_i \equiv (x_{i1} \ x_{i2} \ \cdots \ x_{iK})'$ ，而参数  $\boldsymbol{\beta} \equiv (\beta_1 \ \beta_2 \ \cdots \ \beta_K)'$

线性概率模型的优点是，计算方便( $y$ 为虚拟变量并不影响 OLS 估计)，且容易得到边际效应(即回归系数)。

缺点是，明知被解释变量  $y$  的取值非 0 即 1，但根据线性概率模型所作的预测值却可能出现  $\hat{y} > 1$  或  $\hat{y} < 0$  的不现实情形，参见图 11.1。

故一般只将 LPM 作为粗略的参考。




图 11.1 线性概率模型

为使  $y$  的预测值总是介于  $[0, 1]$  之间，在给定  $\mathbf{x}$  的情况下，考虑  $y$  的两点分布概率：

$$\begin{cases} P(y = 1 | \mathbf{x}) = F(\mathbf{x}, \boldsymbol{\beta}) \\ P(y = 0 | \mathbf{x}) = 1 - F(\mathbf{x}, \boldsymbol{\beta}) \end{cases} \quad (11.2)$$

函数  $F(\mathbf{x}, \boldsymbol{\beta})$  称为连接函数(link function)，它将解释变量  $\mathbf{x}$  与被解释变量  $y$  连接起来。

由于  $y$  的取值要么为 0，要么为 1，故  $y$  肯定服从两点分布。

连接函数的选择具有一定的灵活性。

通过选择合适的连接函数  $F(\mathbf{x}, \boldsymbol{\beta})$  (比如，某随机变量的累积分布函数)，可以保证  $0 \leq \hat{y} \leq 1$

可将  $\hat{y}$  理解为 “ $y = 1$ ” 发生的条件概率，因为

$$E(y \mid \mathbf{x}) = 1 \cdot P(y = 1 \mid \mathbf{x}) + 0 \cdot P(y = 0 \mid \mathbf{x}) = P(y = 1 \mid \mathbf{x}) \quad (11.3)$$

如果  $F(\mathbf{x}, \boldsymbol{\beta})$  为标准正态的累积分布函数(cdf)，则

$$P(y = 1 \mid \mathbf{x}) = F(\mathbf{x}, \boldsymbol{\beta}) = \Phi(\mathbf{x}'\boldsymbol{\beta}) \equiv \int_{-\infty}^{\mathbf{x}'\boldsymbol{\beta}} \phi(t) dt \quad (11.4)$$

其中， $\phi(\cdot)$  与  $\Phi(\cdot)$  分别为标准正态的密度函数与累积分布函数。

此模型称为 Probit。

如果  $F(\mathbf{x}, \boldsymbol{\beta})$  为“逻辑分布”(logistic distribution)的累积分布函数, 则

$$P(y = 1 | \mathbf{x}) = F(\mathbf{x}, \boldsymbol{\beta}) = \Lambda(\mathbf{x}'\boldsymbol{\beta}) \equiv \frac{\exp(\mathbf{x}'\boldsymbol{\beta})}{1 + \exp(\mathbf{x}'\boldsymbol{\beta})} \quad (11.5)$$

其中, 函数  $\Lambda(\cdot)$  的定义为  $\Lambda(z) \equiv \frac{\exp(z)}{1 + \exp(z)}$ 。

此模型称为 **Logit**。

逻辑分布的密度函数关于纵轴对称, 期望为 0, 方差为  $\pi^2/3$  (大于标准正态的方差), 具有厚尾(fat tails), 参见图 11.2。




图 11.2 标准正态分布与逻辑分布的累积分布函数



在实践中，Probit 与 Logit 都很常用，二者的估计结果(比如边际效应)也通常很接近。

Logit 模型的优势在于，逻辑分布的累积分布函数有解析表达式(而标准正态分布没有)，故计算 Logit 更为方便

Logit 的回归系数更容易解释其经济意义。

## 11.2 最大似然估计的原理

Probit 与 Logit 模型在本质上都是非线性模型，无法通过变量转换而变为线性模型。

对于非线性模型，常使用最大似然估计法(Maximum Likelihood Estimation, 简记 MLE 或 ML)。回顾概率统计中的最大似然估计。

假设随机变量  $y$  的概率密度函数为  $f(y; \theta)$ ，其中  $\theta$  为未知参数。为了估计  $\theta$ ，从  $y$  的总体中抽取样本容量为  $n$  的随机样本  $\{y_1, \dots, y_n\}$ 。

假设  $\{y_1, \dots, y_n\}$  为 iid，则样本数据的联合密度函数为

$$f(y_1; \theta) f(y_2; \theta) \cdots f(y_n; \theta) = \prod_{i=1}^n f(y_i; \theta) \quad (11.6)$$

其中， $\prod_{i=1}^n$  表示连乘。

在抽样之前， $\{y_1, \dots, y_n\}$ 为随机向量。

抽样之后， $\{y_1, \dots, y_n\}$ 就有了特定的样本值。

可将样本的联合密度函数视为在给定 $\{y_1, \dots, y_n\}$ 情况下，未知参数 $\theta$ 的函数。定义似然函数(likelihood function)为

$$L(\theta; y_1, \dots, y_n) = \prod_{i=1}^n f(y_i; \theta) \quad (11.7)$$

似然函数与联合密度函数完全相等，只是 $\theta$ 与 $\{y_1, \dots, y_n\}$ 的角色互换，即把 $\theta$ 作为自变量，而视 $\{y_1, \dots, y_n\}$ 为给定。

将乘积的形式转化为求和的形式，得到对数似然函数 (log-likelihood function):

$$\ln L(\theta; y_1, \dots, y_n) = \sum_{i=1}^n \ln f(y_i; \theta) \quad (11.8)$$

最大似然估计法的思想：给定样本取值后，该样本最有可能来自参数 $\theta$ 为何值的总体。

寻找 $\hat{\theta}_{\text{ML}}$ ，使得观测到样本数据的可能性最大，即最大化对数似然函数：

$$\max_{\theta} \ln L(\theta; y_1, \dots, y_n) \quad (11.9)$$

假设存在唯一内点解，则此无约束极值问题的一阶条件为

$$\frac{\partial \ln L(\theta; y_1, \dots, y_n)}{\partial \theta} = 0 \quad (11.10)$$

求解此一阶条件，即可得到最大似然估计量 $\hat{\theta}_{\text{ML}}$ 。

例 假设  $y \sim N(\mu, \sigma^2)$ ，其中  $\sigma^2$  已知，得到一个样本容量为 1 的样本  $y_1 = 2$ ，求对  $\mu$  的最大似然估计。

根据正态分布的密度函数可知，此样本的似然函数为

$$L(\mu) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{\frac{-(2-\mu)^2}{2\sigma^2}\right\} \quad (11.11)$$

此似然函数在  $\hat{\mu} = 2$  处取最大值，参见图 11.3。




图 11.3 选择参数使观测到样本的可能性最大

例(非正式) 某人操一口浓重的四川口音，则判断他最有可能来自四川。

在一定的正则条件(regularity conditions)下, MLE 估计量具有以下良好的大样本性质, 可照常进行大样本统计推断。

(1)  $\hat{\theta}_{\text{ML}}$  为一致估计, 即  $\text{plim } \hat{\theta}_{\text{ML}} = \theta$ 。

(2)  $\hat{\theta}_{\text{ML}}$  服从渐近正态分布。

(3) 在大样本下,  $\hat{\theta}_{\text{ML}}$  是最有效率的估计(渐近方差最小)。

由于模型存在非线性，故最大似然估计通常没有解析解，而只能寻找“数值解”(numerical solution)。

在实践中，一般使用“迭代法”(iteration)进行数值求解。

常用的迭代法为高斯-牛顿法(Gauss-Newton method)。

MLE 的一阶条件可以归结为求非线性方程  $f(x) = 0$  的解。

假设  $f(x)$  的导数  $f'(x)$  处处存在，参见图 11.4。

记该方程的解为  $x^*$ ，满足  $f(x^*) = 0$ 。






图 11.4 高斯-牛顿法

高斯-牛顿法之所以常用，原因之一是它的收敛速度很快，是二次的。

比如，如果本次迭代的误差为 0.1，则下次迭代的误差约为  $0.1^2$ ，而下下次迭代的误差约为  $0.1^4$ ，等等。

如果初始值  $x_0$  选择不当，也可能出现迭代不收敛的情形。

使用牛顿法得到的可能只是“局部最大值” (local maximum)，而非“整体最大值” (global maximum)。

MLE 很容易应用于多参数的情形。

假设随机变量  $y$  的概率密度函数为  $f(y; \boldsymbol{\theta})$ ，其中  $\boldsymbol{\theta} = (\theta_1 \ \theta_2)'$ ，  
则对数似然函数为

$$\ln L(\boldsymbol{\theta}; y_1, \cdots, y_n) = \sum_{i=1}^n \ln f(y_i; \boldsymbol{\theta}) \quad (11.12)$$

此最大化问题的一阶条件为

$$\begin{cases} \frac{\partial \ln L(\boldsymbol{\theta}; y_1, \cdots, y_n)}{\partial \theta_1} = 0 \\ \frac{\partial \ln L(\boldsymbol{\theta}; y_1, \cdots, y_n)}{\partial \theta_2} = 0 \end{cases} \quad (11.13)$$

求解此联立方程组(11.13)，即可得到最大似然估计量  $\hat{\theta}_{1, \text{ML}}$  与  $\hat{\theta}_{2, \text{ML}}$ 。

高斯-牛顿法也适用于多元函数  $f(\mathbf{x}) = 0$  的情形，只要在上述迭代过程中，将切线替换为(超)切平面即可。

### 11.3 二值选择模型的 MLE 估计

以 Logit 模型为例，将 MLE 应用于二值选择模型。对于样本数据  $\{\mathbf{x}_i, y_i\}_{i=1}^n$ ，根据方程(11.5)，第  $i$  个观测数据的概率为

$$f(y_i | \mathbf{x}_i, \boldsymbol{\beta}) = \begin{cases} \Lambda(\mathbf{x}_i' \boldsymbol{\beta}), & \text{若 } y_i = 1 \\ 1 - \Lambda(\mathbf{x}_i' \boldsymbol{\beta}), & \text{若 } y_i = 0 \end{cases} \quad (11.14)$$

其中， $\Lambda(z) \equiv \frac{\exp(z)}{1 + \exp(z)}$  为逻辑分布的累积分布函数。上式可更紧凑地写为

$$f(y_i | \mathbf{x}_i, \boldsymbol{\beta}) = [\Lambda(\mathbf{x}_i' \boldsymbol{\beta})]^{y_i} [1 - \Lambda(\mathbf{x}_i' \boldsymbol{\beta})]^{1-y_i} \quad (11.15)$$

如果  $y_i = 1$ ，则  $1 - y_i = 0$ ，故上式等于  $[\Lambda(\mathbf{x}_i' \boldsymbol{\beta})]$ ；反之，如果  $y_i = 0$ ，则  $1 - y_i = 1$ ，故上式等于  $[1 - \Lambda(\mathbf{x}_i' \boldsymbol{\beta})]$ 。

将上式取对数可得

$$\ln f(y_i | \mathbf{x}_i, \boldsymbol{\beta}) = y_i \ln[\Lambda(\mathbf{x}_i' \boldsymbol{\beta})] + (1 - y_i) \ln[1 - \Lambda(\mathbf{x}_i' \boldsymbol{\beta})] \quad (11.16)$$

假设样本中的个体相互独立，则整个样本的对数似然函数为

$$\ln L(\boldsymbol{\beta} \mid \mathbf{y}, \mathbf{x}) = \sum_{i=1}^n y_i \ln[\Lambda(\mathbf{x}_i' \boldsymbol{\beta})] + \sum_{i=1}^n (1 - y_i) \ln[1 - \Lambda(\mathbf{x}_i' \boldsymbol{\beta})] \quad (11.17)$$

把对数似然函数对  $\boldsymbol{\beta}$  求偏导，即可得到最大化的一阶条件。

满足此一阶条件的估计量即为 MLE 估计量，记为  $\hat{\boldsymbol{\beta}}_{\text{ML}}$ 。

根据 MLE 的一般理论， $\hat{\boldsymbol{\beta}}_{\text{ML}}$  为  $\boldsymbol{\beta}$  的一致估计量，服从渐近正态分布，且在大样本下具有最小渐近方差。

## 11.4 边际效应

对于线性模型，回归系数 $\beta_k$ 的经济意义十分明显，就是解释变量 $x_k$ 对被解释变量 $y$ 的边际效应(marginal effects)。

在非线性模型中，估计量 $\hat{\beta}_{ML}$ 一般并非边际效应。

以 Probit 为例，计算解释变量 $x_k$ 的边际效应：

$$\frac{\partial P(y=1 | \mathbf{x})}{\partial x_k} = \frac{\partial \Phi(\mathbf{x}'\boldsymbol{\beta})}{\partial x_k} = \frac{\partial \Phi(\mathbf{x}'\boldsymbol{\beta})}{\partial (\mathbf{x}'\boldsymbol{\beta})} \cdot \frac{\partial (\mathbf{x}'\boldsymbol{\beta})}{\partial x_k} = \phi(\mathbf{x}'\boldsymbol{\beta}) \cdot \beta_k$$

(11.18)

使用了微分的链式法则(chain rule)，且假定 $x_k$ 为连续变量。

由于 Probit 与 Logit 所使用的分布函数不同，故其参数估计值并不直接可比。

需要分别计算二者的边际效应，然后进行比较。

由表达式(11.18)可知，对于非线性模型而言，边际效应通常不是常数，它随着解释向量 $\mathbf{x}$ 而变。

由于非线性模型的边际效应一般不是常数，故存在不同的边际效应概念。常用的边际效应概念包括：

(1) 平均边际效应(average marginal effect)，即分别计算在每个样本观测值上的边际效应，然后进行简单算术平均。



(2) 样本均值处的边际效应(marginal effect at mean), 即计算在  $\mathbf{x} = \bar{\mathbf{x}}$  处的边际效应。

(3) 某代表值处的边际效应(marginal effect at a representative value), 即给定  $\mathbf{x}^*$ , 计算在  $\mathbf{x} = \mathbf{x}^*$  处的边际效应。

以上三种边际效应的计算结果可能有较大差异。传统上, 常计算样本均值处  $\mathbf{x} = \bar{\mathbf{x}}$  的边际效应, 因为计算方便。

但在非线性模型中, 样本均值处的个体行为并不等于样本中个体的平均行为。

对于政策分析而言, 使用平均边际效应(Stata 的默认方法), 或在某代表值处的边际效应通常更有意义。

## 11.5 回归系数的经济意义

既然  $\hat{\beta}_{\text{ML}}$  并非边际效应，那么它究竟有什么含义？

对于 Logit 模型，记事件发生的概率为  $p \equiv \text{P}(y = 1 | \mathbf{x})$ ，则事件不发生的概率为  $1 - p = \text{P}(y = 0 | \mathbf{x})$ 。

由于  $p = \frac{\exp(\mathbf{x}'\boldsymbol{\beta})}{1 + \exp(\mathbf{x}'\boldsymbol{\beta})}$ ， $1 - p = \frac{1}{1 + \exp(\mathbf{x}'\boldsymbol{\beta})}$ ，故事件发生与不发生的几率为

$$\frac{p}{1 - p} = \exp(\mathbf{x}'\boldsymbol{\beta}) \quad (11.19)$$

$\frac{p}{1-p}$  称为几率(odds)或相对风险(relative risk)。

例如，在一个检验药物疗效的随机实验中，“ $y = 1$ ”表示“生”，而“ $y = 0$ ”表示“死”。

如果几率为 2，则意味着存活概率是死亡概率的两倍。

对方程(11.19)两边取对数可得

$$\ln\left(\frac{p}{1-p}\right) = \mathbf{x}'\boldsymbol{\beta} = \beta_1 x_1 + \cdots + \beta_K x_K \quad (11.20)$$

$\ln\left(\frac{p}{1-p}\right)$ 称为对数几率(log-odds)，而上式右边为线性函数。

回归系数 $\hat{\beta}_j$ 表示解释变量 $x_j$ 增加一个微小量引起对数几率的边际变化。

由于取对数意味着百分比的变化，故可把 $\hat{\beta}_j$ 视为半弹性(semi-elasticity)，即 $x_j$ 增加一单位引起几率 $\left(\frac{p}{1-p}\right)$ 的变化百分比。

比如， $\hat{\beta}_j = 0.12$ ，意味着 $x_j$ 增加一单位引起几率增加 12%。

以上解释隐含地假设 $x_j$ 为连续变量。

如果 $x_j$ 为离散变量(比如, 性别、子女数), 则可使用另一解释方法。

假设 $x_j$ 增加一单位, 从 $x_j$ 变为 $x_j+1$ , 记事件发生概率 $p$ 的新值为 $p^*$ , 则新几率与原几率的比值可写为(此处无法使用微积分)

$$\frac{\frac{p^*}{1-p^*}}{\frac{p}{1-p}} = \frac{\exp[\beta_1 + \beta_2 x_2 + \cdots + \beta_j (x_j + 1) + \cdots + \beta_K x_K]}{\exp(\beta_1 + \beta_2 x_2 + \cdots + \beta_j x_j + \cdots + \beta_K x_K)} = \exp(\beta_j)$$

(11.21)

有些研究者偏好计算 $\exp(\hat{\beta}_j)$ ，它表示解释变量 $x_j$ 增加一单位引起几率的变化倍数。

Stata 称 $\exp(\hat{\beta}_j)$ 为几率比(odds ratio)。

例  $\hat{\beta}_j = 0.12$ ，则 $\exp(\hat{\beta}_j) = e^{0.12} = 1.13$ ，故当 $x_j$ 增加一单位时，新几率是原几率的 1.13 倍，或增加 13%，因为 $\exp(\hat{\beta}_j) - 1 = 1.13 - 1 = 0.13$ 。

如果 $\hat{\beta}_j$ 较小，则 $\exp(\hat{\beta}_j) - 1 \approx \hat{\beta}_j$ (将 $\exp(\hat{\beta}_j)$ 泰勒展开)，此时以上两种方法等价。

如果  $x_j$  至少必须变化一个单位(比如性别、婚否等虚拟变量, 以及年龄, 子女个数等), 则应使用  $\exp(\hat{\beta}_j)$ 。

对于 Probit 模型, 无法对其系数  $\hat{\beta}_{ML}$  进行类似的解释。这是 Probit 模型的劣势。

## 11.6 拟合优度

如何衡量(非线性)二值模型的拟合优度呢?

由于不存在平方和分解公式, 故无法计算  $R^2$ 。

Stata 仍然汇报一个准  $R^2$  (Pseudo  $R^2$ ), 由 McFadden (1974) 所提出, 其定义为

$$\text{准}R^2 \equiv \frac{\ln L_0 - \ln L_1}{\ln L_0} \quad (11.22)$$

其中， $\ln L_1$  为原模型的对数似然函数之最大值，而  $\ln L_0$  为以常数项为唯一解释变量的对数似然函数之最大值。

由于  $y$  为离散的两点分布，似然函数的最大可能值为 1 (即取值概率为 1)，故对数似然函数的最大可能值为 0，记为  $\ln L_{\max}$ 。

显然， $0 \geq \ln L_1 \geq \ln L_0$ ，而  $0 \leq \text{准}R^2 \leq 1$ ，参见图 11.5。

由于  $\ln L_{\max} = 0$ ，故可将“准  $R^2$ ” 写为

$$\text{准}R^2 = \frac{\ln L_1 - \ln L_0}{\ln L_{\max} - \ln L_0} \quad (11.23)$$



分子为加入解释变量后，对数似然函数的实际增加值  $(\ln L_1 - \ln L_0)$ ；而分母为最大可能增加值  $(\ln L_{\max} - \ln L_0)$ 。




图 11.5 准  $R^2$  的计算

判断拟合优度的另一方法是计算正确预测百分比(percent correctly predicted)。

如果发生概率的预测值  $\hat{y} \geq 0.5$ ，则认为其预测  $y = 1$ ；反之，则认为其预测  $y = 0$ 。

将预测值与实际值(样本数据)进行比较，即可计算正确预测的百分比。

## 11.7 准最大似然估计

使用 MLE 的前提是对总体的分布函数作具体的假定。

比如，Probit 与 Logit 模型分别假设被解释变量  $y$  的两点分布概率由标准正态或逻辑分布的累积分布函数所给出。

但此分布函数的设定可能不正确，即存在“设定误差”(specification error)。

**定义** 使用不正确的分布函数所得到的最大似然估计量，称为**准最大似然估计**(Quasi MLE, 简记 QMLE)或**伪最大似然估计**(Pseudo MLE)。

准最大似然估计是否一定不一致？

不一定！

例如，假设线性模型的扰动项服从正态分布，则 MLE 估计量与 OLS 估计量完全相同，而 OLS 估计量的一致性并不依赖于关于分布函数的具体假设。

关于 QMLE 估计量的标准误可分为以下两种情况考虑。

(1) 如果 QMLE 为一致估计量，考虑到可能存在对分布函数的设定误差，故应使用稳健标准误(robust standard errors)，即相对于模型设定稳健的标准误。

此稳健标准误与异方差稳健的标准误是一致的，因为扰动项方差是否相同也是一种模型设定。

(2) 如果 QMLE 估计量不一致，则即使采用稳健标准误也无济于事。

此时，QMLE 估计量  $\hat{\boldsymbol{\beta}}_{\text{QML}} \xrightarrow{p} \boldsymbol{\beta}^* \neq \boldsymbol{\beta}$ ，故首先应担心估计量的一致性

。

稳健标准误只是更精确估计了一个错误的**准真实参数**(pseudo true parameter) $\boldsymbol{\beta}^*$ ，而且通常不知道 $\boldsymbol{\beta}^*$ 的经济意义。

在这种情况下，稳健标准误只是一致地估计了一个不一致估计量的方差(a consistent estimator of the variance of an inconsistent estimator)。

具体到二值选择模型(Probit 或 Logit 模型), 只要条件期望函数  $E(y | \mathbf{x}) = F(\mathbf{x}, \boldsymbol{\beta})$  设定正确, 则 MLE 估计就是一致的。

由于两点分布的特殊性, 在 iid 的情况下, 只要  $E(y | \mathbf{x}) = F(\mathbf{x}, \boldsymbol{\beta})$  成立, 则稳健标准误就等于 MLE 的普通标准误。

因此, 如果认为模型设定正确, 就没有必要使用稳健标准误(但使用稳健标准误也没有错)。

反之, 如果模型设定不正确(即  $E(y | \mathbf{x}) \neq F(\mathbf{x}, \boldsymbol{\beta})$ ), 则 Probit 与 Logit 模型并不能得到对系数  $\boldsymbol{\beta}$  的一致估计, 使用稳健标准误也就没有太大意义。

对于二值选择模型，使用普通标准误或稳健标准误都可以(文献中尚无定论)。

## 11.8 三类渐近等价的大样本检验

在计量经济学中，经常使用以下三类在大样本下渐近等价的统计检验。

考虑以下线性回归模型：

$$y_i = \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_K x_K + \varepsilon_i = \mathbf{x}_i' \boldsymbol{\beta} + \varepsilon_i \quad (i = 1, \cdots, n)$$

(11.24)

其中，解释变量  $\mathbf{x} \equiv (x_1 \ x_2 \ \cdots \ x_K)'$ ，而参数  $\boldsymbol{\beta} \equiv (\beta_1 \ \beta_2 \ \cdots \ \beta_K)'$ 。

考虑检验以下原假设：

$$H_0 : \boldsymbol{\beta} = \boldsymbol{\beta}_0 \quad (11.25)$$

其中， $\boldsymbol{\beta}_0$  已知，共有  $K$  个约束。

(1) 沃尔德检验(Wald Test)：沃尔德检验通过考察  $\boldsymbol{\beta}$  的无约束估计量  $\hat{\boldsymbol{\beta}}$  与  $\boldsymbol{\beta}_0$  的距离来进行检验。

如果  $H_0$  正确，则  $(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}_0)$  的绝对值不应该很大。

由于  $(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}_0)$  为多维向量，故使用以下二次型：

$$W \equiv (\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}_0)' [\text{Var}(\hat{\boldsymbol{\beta}})]^{-1} (\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}_0) \xrightarrow{d} \chi^2(K) \quad (11.26)$$



在大样本下，此 Wald 统计量服从渐近  $\chi^2(K)$  分布，其中  $K$  为约束条件的个数(在此为解释变量个数)。

第 5-6 章所介绍的单一系数  $t$  检验(在大样本下使用标准正态进行检验)、联合线性假设的  $F$  检验(大样本下可使用  $\chi^2$  分布进行检验)都是 Wald 检验。

## (2) 似然比检验(Likelihood Ratio Test, 简记 $LR$ ):

似然比检验通过比较无约束估计量  $\hat{\beta}$  与有约束估计量  $\hat{\beta}^*$  的差别来进行检验。

无约束的似然函数最大值  $\ln L(\hat{\beta})$  比有约束的似然函数最大值  $\ln L(\hat{\beta}^*)$  更大

因为在无约束条件下的参数空间 $\Theta$ 比有约束条件下(即 $H_0$ 成立时)参数的取值范围更大, 参见图 11.6。




图 11.6 无约束与有约束的参数空间

如果 $H_0$ 正确，则 $[\ln L(\hat{\boldsymbol{\beta}}) - \ln L(\hat{\boldsymbol{\beta}}^*)]$ 不应该很大。

在此例中，有约束的估计量 $\hat{\boldsymbol{\beta}}^* = \boldsymbol{\beta}_0$ 。

$LR$ 统计量为

$$LR \equiv -2 \ln \left[ \frac{L(\hat{\boldsymbol{\beta}}^*)}{L(\hat{\boldsymbol{\beta}})} \right] = 2 \left[ \ln L(\hat{\boldsymbol{\beta}}) - \ln L(\hat{\boldsymbol{\beta}}^*) \right] \xrightarrow{d} \chi^2(K)$$

(11.27)

在大样本下， $LR$ 统计量也服从渐近 $\chi^2(K)$ 分布。

第 5 章  $F$  统计量的另一表达式  $F = \frac{(\text{SSR}^* - \text{SSR}) / (K - 1)}{\text{SSR} / (n - K)}$ , 就可

看成是依据似然比原理而设计的。

在进行 Probit 或 Logit 回归时, Stata 会汇报一个似然比统计量, 检验除常数项外所有参数的联合显著性, 即考察原模型与只有常数项模型的似然函数最大值之比(准  $R^2$  的计算也基于此)。

(3) 拉格朗日乘子检验(Lagrange Multiplier Test, 简记  $LM$ ):

Wald 检验只考察无约束估计量  $\hat{\beta}$ ,  $LR$  检验同时考察无约束估计量  $\hat{\beta}$  与有约束估计量  $\hat{\beta}^*$ 。

$LM$  检验则只考察有约束估计量  $\hat{\beta}^*$ 。

考虑以下有约束条件的对数似然函数最大化问题：

$$\begin{aligned} \max_{\tilde{\boldsymbol{\beta}}} \ln L(\tilde{\boldsymbol{\beta}}) \\ s.t. \quad \tilde{\boldsymbol{\beta}} = \boldsymbol{\beta}_0 \end{aligned} \quad (11.28)$$

$\tilde{\boldsymbol{\beta}}$  为在最大化过程中假想的参数  $\boldsymbol{\beta}$  取值(hypothetical value)。

对于约束极值问题，可引入以下拉格朗日乘子函数：

$$\max_{\tilde{\boldsymbol{\beta}}, \boldsymbol{\lambda}} \ln L(\tilde{\boldsymbol{\beta}}) - \boldsymbol{\lambda}'(\tilde{\boldsymbol{\beta}} - \boldsymbol{\beta}_0) \quad (11.29)$$

其中， $\boldsymbol{\lambda}$  为拉格朗日乘子向量(Lagrange Multiplier)，其经济含义为约束条件(比如资源约束)的影子价格(shadow price)。

如果 $\hat{\lambda} = \mathbf{0}$ , 则此约束条件完全不起作用(可以无偿获取任意数量的资源)。

根据一阶条件(对 $\tilde{\beta}$ 求导)可知,

$$\hat{\lambda} = \frac{\partial \ln L(\hat{\beta}^*)}{\partial \tilde{\beta}} \equiv \begin{pmatrix} \frac{\partial \ln L(\hat{\beta}^*)}{\partial \tilde{\beta}_1} \\ \vdots \\ \frac{\partial \ln L(\hat{\beta}^*)}{\partial \tilde{\beta}_K} \end{pmatrix} \quad (11.30)$$

最优的拉格朗日乘子向量 $\hat{\lambda}$ 等于对数似然函数在约束估计量 $\hat{\beta}^*$ 处的一阶偏导数(切线的斜率)。

如果  $\hat{\lambda} \approx \mathbf{0}$ ，则说明此约束条件不“紧”(tight)或不是“硬约束”(binding constraint)，加上这个约束条件并不会使似然函数的最大值下降很多，即原假设  $H_0$  很可能成立。

如果原假设  $H_0$  成立，则  $(\hat{\lambda} - \mathbf{0})$  的绝对值不应很大。

以二次型来度量此距离，可得  $LM$  统计量：

$$LM \equiv \hat{\lambda}' [\text{Var}(\hat{\lambda})]^{-1} \hat{\lambda} \xrightarrow{d} \chi^2(K) \quad (11.31)$$

其中， $LM$  统计量也服从渐近  $\chi^2(K)$  分布，而  $\text{Var}(\hat{\lambda})$  为  $\hat{\lambda}$  的协方差矩阵。

由于似然函数的一阶导  $\hat{\lambda} = \frac{\partial \ln L(\tilde{\beta})}{\partial \tilde{\beta}}$  被称为得分函数(score function)或得分向量(score vector), 故此检验也称为得分检验(score test)。

由于在无约束估计量  $\hat{\beta}$  处,  $\frac{\partial \ln L(\hat{\beta})}{\partial \tilde{\beta}} = \mathbf{0}$  (MLE 的一阶条件), 故如果原假设  $H_0$  成立, 则在约束估计量  $\hat{\beta}^*$  处, 此得分向量也应该接近于  $\mathbf{0}$ , 即  $\frac{\partial \ln L(\hat{\beta}^*)}{\partial \tilde{\beta}} \approx \mathbf{0}$ , 而  $LM$  统计量反映的就是此接近程度。

在第 7-8 章, 对异方差与自相关所进行的  $nR^2$  形式的检验都来自于  $LM$  检验的推导。



Wald 检验仅利用无约束估计的信息， $LM$  检验仅利用有约束估计的信息，而 $LR$ 检验同时利用无约束与有约束估计的信息。

这三类检验在大样本下是渐近等价的，它们只是从不同的侧面去考察同一事物。

可以把这三类统计检验的思想画在同一张图上，参见图 11.7。

在实际应用中，究竟采取哪种检验常取决于“无约束估计”与“有约束估计”哪种更方便。

如果无约束估计更方便，则常使用 Wald 检验(比如，对线性回归系数的显著性检验)；如果有约束估计更方便，则常使用 $LM$ 检验(比如，对异方差、自相关的检验)；如果二者都方便，则可使用 $LR$ 检验(比如，对非线性回归方程的显著性检验)。




图 11.7 三类渐近等价的统计检验

## 11.9 二值选择模型的 Stata 命令与实例

二值模型的 Stata 命令为

`. probit y x1 x2 x3,r` (probit 模型)

`. logit y x1 x2 x3,r or` (logit 模型)

选择项 “r” 表示使用稳健标准误(默认为普通标准误);

选择项 “or” 表示显示几率比(odds ratio), 而不显示回归系数。

完成 Probit 或 Logit 估计后, 可进行预测, 计算准确预测的百分比, 或计算边际效应:

- `. predict y1` (计算发生概率的预测值, 记为 `y1`)
- `. estat clas` (计算准确预测的百分比, `clas` 表示 classification)
- `. margins, dydx(*)` (计算所有解释变量的平均边际效应; “\*” 代表所有解释变量)
- `. margins, dydx(*) atmeans` (计算所有解释变量在样本均值处的边际效应)
- `. margins, dydx(*) at(x1=0)` (计算所有解释变量在 `x1 = 0` 处的平均边际效应)

- `. margins, dydx(x1` (计算解释变量  $x_1$  的平均边际效应)
- `. margins, eyex(*)` (计算平均弹性, 其中的两个“e”  
均指 elasticity)
- `. margins, eydx(*)` (计算平均半弹性,  $x$  变化一单位引  
起  $y$  变化百分之几)
- `. margins, dyex(*)` (计算平均半弹性,  $x$  变化 1% 引起  $y$   
变化几个单位)

以数据集 `titanic.dta` 为例, 演示二值选择模型的 Stata 估计。

该数据集包括泰坦尼克号乘客的存活数据。

被解释变量为 *survive*(存活=1, 死亡=0)。

解释变量包括 *child*(儿童=1, 成年=0), *female*(女性=1, 男性=0), *class1*(头等舱=1, 其他=0), *class2*(二等舱=1, 其他=0), *class3*(三等舱=1, 其他=0), *class4*(船员=1, 其他=0)。

在生死的紧要关头, 各色人等的存活概率几何?




图 11.8 泰坦尼克号于 1914 年 4 月 10 日从英国南安普顿港出发

首先打开数据集，看一下原始数据。

```
. use titanic.dta,clear  
. list
```

	class1	class2	class3	class4	child	female	survive	freq
1.	0	0	1	0	1	0	0	35
2.	0	0	1	0	1	1	0	17
3.	1	0	0	0	0	0	0	118
4.	0	1	0	0	0	0	0	154
5.	0	0	1	0	0	0	0	387
6.	0	0	0	1	0	0	0	670
7.	1	0	0	0	0	1	0	4
8.	0	1	0	0	0	1	0	13
9.	0	0	1	0	0	1	0	89
10.	0	0	0	1	0	1	0	3
11.	1	0	0	0	1	0	1	5
12.	0	1	0	0	1	0	1	11
13.	0	0	1	0	1	0	1	13
14.	1	0	0	0	1	1	1	1
15.	0	1	0	0	1	1	1	13
16.	0	0	1	0	1	1	1	14
17.	1	0	0	0	0	0	1	57
18.	0	1	0	0	0	0	1	14
19.	0	0	1	0	0	0	1	75
20.	0	0	0	1	0	0	1	192
21.	1	0	0	0	0	1	1	140
22.	0	1	0	0	0	1	1	80
23.	0	0	1	0	0	1	1	76
24.	0	0	0	1	0	1	1	20



原始数据只有 24 个观测值，但每个观测值可能重复多次；其重复次数以最后一列变量 `freq` 来表示。

比如，第一行数据显示，乘坐三等舱的男孩死亡者有 35 人；第二行数据显示，乘坐三等舱的女孩死亡者有 17 人；以此类推。

对于这种观测值重复的数据，在进行计算与估计时，必须以重复次数(`freq`)作为权重才能得到正确的结果。

其效果就相当于在数据文件中，将第一行数据重复 35 次，将第二行数据重复 17 次，以此类推(不同于以方差倒数为权重的加权最小二乘法)。

假设观测值的重复次数记录于变量 `freq`，在 Stata 中可通过在命令的最后加上“`[fweight=freq]`”来实现此加权计算或估计。其中，“`fweight`”指“frequency weight” (频数权重)。

首先看一下各变量的统计特征。

```
. sum [fweight=freq]
```

Variable	Obs	Mean	Std. dev.	Min	Max
class1	2,201	.1476602	.3548434	0	1
class2	2,201	.1294866	.335814	0	1
class3	2,201	.3207633	.466876	0	1
class4	2,201	.40209	.4904313	0	1
child	2,201	.0495229	.2170065	0	1
female	2,201	.2135393	.4098983	0	1
survive	2,201	.323035	.4677422	0	1
freq	2,201	329.2726	250.0362	1	670

样本容量为 2201(旅客与船员总人数)，而非 24。

从变量 `survive` 的平均值可知,泰坦尼克号的平均存活率为 0.32。

分别计算小孩、女士以及各等舱旅客的存活率。

```
. sum survive if child [fweight=freq]
```

Variable	Obs	Mean	Std. dev.	Min	Max
survive	109	.5229358	.5017807	0	1

```
. sum survive if female [fweight=freq]
```

Variable	Obs	Mean	Std. dev.	Min	Max
survive	470	.7319149	.4434342	0	1

```
. sum survive if class1 [fweight=freq]
```

Variable	Obs	Mean	Std. dev.	Min	Max
survive	325	.6246154	.4849687	0	1

```
. sum survive if class2 [fweight=freq]
```

Variable	Obs	Mean	Std. dev.	Min	Max
survive	285	.4140351	.493421	0	1

```
. sum survive if class3 [fweight=freq]
```

Variable	Obs	Mean	Std. dev.	Min	Max
survive	706	.2521246	.4345403	0	1

```
. sum survive if class4 [fweight=freq]
```

Variable	Obs	Mean	Std. dev.	Min	Max
survive	885	.239548	.427049	0	1

小孩、女士、一等舱、二等舱的存活率分别为 0.52、0.73、0.62、0.41，高于平均存活率

三等舱、船员的存活率分别为 0.25、0.24，低于平均存活率。

下面进行回归分析。作为参照系，首先使用 OLS 估计线性概率模型。

```
. reg survive child female class1 class2 class3  
[fweight=freq],r
```

由于所有乘客分为四类(class1-class4)，故只能放入三个虚拟变量(class1-class3)

将虚拟变量 class4(船员)作为参照类别，不放入回归方程。

Linear regression			Number of obs	=	2,201	
			F(5, 2195)	=	221.66	
			Prob > F	=	0.0000	
			R-squared	=	0.2529	
			Root MSE	=	.40474	
survive	Coefficient	Robust std. err.	t	P> t	[95% conf. interval]	
child	.1812957	.0479499	3.78	0.000	.0872639	.2753275
female	.4906798	.0239292	20.51	0.000	.4437535	.5376061
class1	.1755538	.0291386	6.02	0.000	.1184117	.232696
class2	-.0105263	.0258402	-0.41	0.684	-.0612	.0401475
class3	-.1311806	.0212996	-6.16	0.000	-.17295	-.0894112
_cons	.2267959	.0139872	16.21	0.000	.1993664	.2542254

儿童(child)、妇女(female)与头等舱旅客(class1)的存活概率均显著地更高，三等舱旅客(class3)的存活概率显著地更低，而二等舱旅客(class2)的存活概率与船员无显著差异。

其次，使用 Logit 进行估计：

```
. logit survive child female class1 class2 class3  
[fweight=freq],nolog
```

其中，选择项 “nolog” 表示不显示 MLE 数值计算的迭代过程。



Logistic regression				Number of obs = 2,201		
				LR chi2(5) = 559.40		
				Prob > chi2 = 0.0000		
Log likelihood = -1105.0306				Pseudo R2 = 0.2020		
survive	Coefficient	Std. err.	z	P> z	[95% conf. interval]	
child	1.061542	.2440257	4.35	0.000	.5832608	1.539824
female	2.42006	.1404101	17.24	0.000	2.144862	2.695259
class1	.8576762	.1573389	5.45	0.000	.5492976	1.166055
class2	-.1604188	.1737865	-0.92	0.356	-.5010342	.1801966
class3	-.9200861	.1485865	-6.19	0.000	-1.21131	-.6288619
_cons	-1.233899	.0804946	-15.33	0.000	-1.391666	-1.076133

Logit 的估计结果在显著性方面与 OLS 完全一致。准  $R^2$  为 0.20。

检验整个方程显著性的  $LR$  统计量(LR chi2(5))为 559.40，对应的  $p$  值为 0.000，故整个方程的联合显著性很高。

下面使用稳健标准误进行 Logit 估计。

```
. logit survive child female class1 class2 class3
[fweight=freq],nolog r
```

Logistic regression					Number of obs = 2,201	
					Wald chi2(5) = 467.05	
					Prob > chi2 = 0.0000	
Log pseudolikelihood = -1105.0306					Pseudo R2 = 0.2020	
survive	Coefficient	Robust std. err.	z	P> z	[95% conf. interval]	
child	1.061542	.2767452	3.84	0.000	.5191318	1.603953
female	2.42006	.1363096	17.75	0.000	2.152898	2.687222
class1	.8576762	.1475218	5.81	0.000	.5685387	1.146814
class2	-.1604188	.1502193	-1.07	0.286	-.4548432	.1340056
class3	-.9200861	.1621035	-5.68	0.000	-1.237803	-.602369
_cons	-1.233899	.0798876	-15.45	0.000	-1.390476	-1.077322

稳健标准误与普通标准误比较接近。

由于此回归中的解释变量均为虚拟变量，只能变化一个单位(从 0 变为 1)，为了便于解释回归结果，让 Stata 汇报几率比而非系数。

```
. logit survive child female class1 class2 class3
[fweight=freq],or nolog
```

Logistic regression					Number of obs = 2,201	
					LR chi2(5) = 559.40	
					Prob > chi2 = 0.0000	
Log likelihood = -1105.0306					Pseudo R2 = 0.2020	
survive	Odds ratio	Std. err.	z	P> z	[95% conf. interval]	
child	2.890826	.7054359	4.35	0.000	1.791872	4.663769
female	11.24654	1.579128	17.24	0.000	8.540859	14.80936
class1	2.357675	.3709541	5.45	0.000	1.732036	3.209306
class2	.851787	.1480291	-0.92	0.356	.6059037	1.197453
class3	.3984847	.0592095	-6.19	0.000	.2978068	.5331983
_cons	.2911551	.0234364	-15.33	0.000	.2486608	.3409114

Note: **\_cons** estimates baseline odds.

儿童的生存概率是成年人的近 3 倍(几率比为 2.89)。

妇女的存活概率是男人的 11 倍多(几率比为 11.25)。

头等舱旅客的存活概率是船员的 2.36 倍。

三等舱旅客的存活概率只是船员的 39.8%。

二等舱旅客的存活概率也略低于船员(几率比为 0.85), 但此差别在统计上不显著( $p$  值为 0.356)。

为了与 OLS 估计的回归系数比较, 计算 Logit 模型的平均边际效应:

```
. margins, dydx( *)
```

Average marginal effects

Model VCE: OIM

Expression: Pr(survive), predict()  
dy/dx wrt: child female class1 class2 class3

	Delta-method					
	dy/dx	std. err.	z	P> z	[95% conf. interval]	
child	.1732315	.0393799	4.40	0.000	.0960484	.2504147
female	.394926	.0171966	22.97	0.000	.3612214	.4286307
class1	.1399629	.0250922	5.58	0.000	.0907831	.1891427
class2	-.0261785	.0283616	-0.92	0.356	-.0817663	.0294093
class3	-.1501475	.0238334	-6.30	0.000	-.1968602	-.1034348

Logit 模型的平均边际效应与 OLS 回归系数相差不大。

为了演示目的，计算在样本均值处的边际效应。

```
. margins, dydx(*) atmeans
```

Conditional marginal effects

Number of obs = 2,201

Model VCE: OIM

Expression: Pr(survive), predict()

dy/dx wrt: child female class1 class2 class3

At: child = .0495229 (mean)

female = .2135393 (mean)

class1 = .1476602 (mean)

class2 = .1294866 (mean)

class3 = .3207633 (mean)

	Delta-method					
	dy/dx	std. err.	z	P> z	[95% conf. interval]	
child	.2223422	.0510772	4.35	0.000	.1222328	.3224516
female	.5068865	.0303542	16.70	0.000	.4473934	.5663797
class1	.179642	.0332374	5.40	0.000	.1144979	.2447861
class2	-.0336	.0363774	-0.92	0.356	-.1048983	.0376983
class3	-.1927139	.0308186	-6.25	0.000	-.2531173	-.1323105

计算 Logit 模型准确预测的比率:

. estat clas

Logistic model for survive			
Classified	True		Total
	D	~D	
+	349	126	475
-	362	1364	1726
Total	711	1490	2201
Classified + if predicted $\Pr(D) \geq .5$			
True D defined as survive $\neq 0$			
Sensitivity	$\Pr(+ D)$		49.09%
Specificity	$\Pr(- \sim D)$		91.54%
Positive predictive value	$\Pr(D +)$		73.47%
Negative predictive value	$\Pr(\sim D -)$		79.03%
False + rate for true ~D	$\Pr(+ \sim D)$		8.46%
False - rate for true D	$\Pr(- D)$		50.91%
False + rate for classified +	$\Pr(\sim D +)$		26.53%
False - rate for classified -	$\Pr(D -)$		20.97%
Correctly classified			77.83%

正确预测的比率为  $(349 + 1364)/2201 = 77.83\%$ 。

根据 Logit 模型的回归结果， 预测每位乘客的存活概率，并记为变量 *prob*。

```
. predict prob  
(option pr assumed; Pr(survive))
```

由此可考察给定某种特征旅客的生存概率。比如，计算 Ms. Rose (头等舱、成年、女性)的存活概率：

```
. list prob survive freq if class1==1 & child==0  
& female==1
```



	prob	survive	freq
7.	.8853235	0	4
21.	.8853235	1	140

Ms. Rose 的存活概率高达 88.5%。

从频率上看，所有头等舱的 144 位成年女性中，只有 4 位死亡。

又比如，计算 Mr. Jack (三等舱、成年、男性)的存活概率：

```
. list prob survive freq if class3==1 & child==0
& female==0
```

	prob	survive	freq
5.	.1039594	0	387
19.	.1039594	1	75

Mr. Jack 的存活概率仅有 10.4%。

从频率上看，所有三等舱的 462 位成年男性中，只有 75 位生还。

类似地，可对此数据集进行 Probit 估计。

```
. probit survive child female class1 class2
class3 [fweight=freq],nolog
```

Probit regression					Number of obs = 2,201	
					LR chi2(5) = 556.83	
					Prob > chi2 = 0.0000	
Log likelihood = -1106.3142					Pseudo R2 = 0.2011	
survive	Coefficient	Std. err.	z	P> z	[95% conf. interval]	
child	.5803382	.1377535	4.21	0.000	.3103463	.85033
female	1.44973	.0808635	17.93	0.000	1.29124	1.608219
class1	.5399101	.0951552	5.67	0.000	.3534092	.7264109
class2	-.0898158	.1028857	-0.87	0.383	-.2914681	.1118364
class3	-.4875252	.0800342	-6.09	0.000	-.6443893	-.3306611
_cons	-.7530486	.0468804	-16.06	0.000	-.8449325	-.6611648

由于 Probit 与 Logit 模型的回归系数并不直接可比，下面考察 Probit 模型的平均边际效应及预测准确度。

```
. margins, dydx(*)
```



Probit model for survive			
Classified	True		Total
	D	~D	
+	349	126	475
-	362	1364	1726
Total	711	1490	2201
Classified + if predicted $\Pr(D) \geq .5$			
True D defined as survive != 0			
Sensitivity	$\Pr(+ D)$		49.09%
Specificity	$\Pr(- \sim D)$		91.54%
Positive predictive value	$\Pr(D +)$		73.47%
Negative predictive value	$\Pr(\sim D -)$		79.03%
False + rate for true ~D	$\Pr(+ \sim D)$		8.46%
False - rate for true D	$\Pr(- D)$		50.91%
False + rate for classified +	$\Pr(\sim D +)$		26.53%
False - rate for classified -	$\Pr(D -)$		20.97%
Correctly classified			77.83%

Probit 模型的平均边际效应、准  $R^2$  与正确预测比率与 Logit 模型十分接近，故可视为基本等价(二者的估计系数虽有差距，但估计系数没有可比性)。

为了进一步验证这一点，下面使用 Probit 模型预测每位个体的存活概率，记为变量 *probl*，并考察 *probl* 与 *prob*(Logit 模型预测结果)的相关性。

```
. predict probl  
(option pr assumed; Pr(survive))  
  
. corr prob probl [fweight=freq]  
(obs=2201)
```

	prob	prob1
prob	1.0000	
prob1	0.9997	1.0000

Probit 与 Logit 模型对个体存活概率的预测结果相关系数高达 0.9997，可以视为无差异。

## 11.10 其他离散选择模型

二值选择模型并非唯一的离散选择模型。其他离散选择模型还包括：

(1) 多值选择(multiple choices): 比如，对交通方式的选择(步行、骑车、自驾车、打的、地铁)，对不同职业的选择，对手机品牌的选择。

(2) 计数数据(count data): 有时被解释变量只能取非负整数。比如, 企业在某段时间内获得的专利数; 某人在一定时间内去医院看病的次数; 某省在一年内发生煤矿事故的次数。

(3) 排序数据(ordered data): 有些离散数据有着天然的排序。比如, 公司债券的评级(AAA, AA, A, B, C 级), 对“春节联欢晚会”的满意度(很满意、满意、不满意、很不满意)。

对于以上离散数据, 一般也不宜直接进行 OLS 回归, 主要估计方法仍为 MLE。

由于离散选择模型主要用于微观经济学的实证研究中, 故是“微观计量经济学”(Microeconometrics)的重要组成部分。



除了离散数据外，微观计量经济学还关注的另一类数据类型为“受限被解释变量” (limited dependent variable)，即被解释变量的取值范围受到限制(包括断尾回归、归并回归与样本选择模型等)。

有关离散选择模型与受限被解释变量的具体介绍，请参见 Wooldridge (2009)或陈强(2014, 2024)。